

# FDU 数值算法 3. 大型稀疏线性方程组的迭代解法

本文根据邵老师授课内容整理而成，并参考了以下教材：

- 数值线性代数 (第二版, 徐树方, 高立, 张平文) 第 4 章
- Applied Numerical Linear Algebra (J. Demmel) Chapter 6
- 应用数值线性代数 (J. Demmel) 第 6 章

欢迎批评指正！

## 3.0 Introduction

求解线性方程组  $Ax = b$  的直接方法大多数都需要对系数矩阵  $A$  进行分解，因而一般不能保持  $A$  的稀疏性。

考虑以下例子：

$$\begin{bmatrix} * & * & * & * \\ * & * & & \\ * & & * & \\ * & & & * \end{bmatrix}$$

一步 Gauss 消元，这种类型的稀疏矩阵就变成稠密矩阵了。

不过也不是不能解决，我们可以将其行列重排为：

$$\begin{bmatrix} * & & & * \\ & * & & * \\ & & * & * \\ * & * & * & * \end{bmatrix}$$

这样 Gauss 消元就能保持稀疏性了。

但在实际应用中，我们常常会遇到大型稀疏线性方程组的求解问题。

目前发展起来的求解稀疏线性方程组的方法主要有两类：

- 一类是稀疏直接法。

它是直接法与某些稀疏矩阵技巧结合的产物，充分利用了给定线性方程组的系数矩阵的零元素的分布特点 (即矩阵的结构)，采用灵活的主元选取策略，使得分解出的矩阵因子尽可能地保持原有的稀疏性。本课程不涉及这类方法。

- 另一类是迭代法，即按照某种规则构造向量序列  $\{x^{(k)}\}$ ，使其极限  $x^*$  是方程组  $Ax = b$  的精确解。我们将主要关注以下问题：

- 如何构造迭代序列  $\{x^{(k)}\}$ ？
- 构造的迭代序列是否收敛？在什么情况下收敛？
- 若迭代序列收敛，则收敛的速度如何？
- 由于实际计算总是有限次的，故我们要讨论近似解的误差估计和迭代过程的中断处理等问题。

### 3.0.1 存储

维度超过百万级别的矩阵就称为大型矩阵。

稀疏矩阵一般按坐标方式 (COO format) 存储： $(i, j, \text{value})$  (并且按列存储，因为列向量比行向量更常用) 以如下矩阵为例：

$$A = \begin{bmatrix} * & & & \\ & * & * & \\ & & * & \\ * & & & * \end{bmatrix}$$

其存储如下：

$$(m, n, \text{nnz}) = (4, 4, 6)$$

$$(i, j, \text{value}) = (0, 0, *)$$

$$(i, j, \text{value}) = (3, 0, *)$$

$$(i, j, \text{value}) = (1, 1, *)$$

$$(i, j, \text{value}) = (1, 2, *)$$

$$(i, j, \text{value}) = (2, 2, *)$$

$$(i, j, \text{value}) = (3, 3, *)$$

其中  $\text{nnz}$  代表 number of non-zero elements, 即非零元素的个数.

但实际应用中是可以存储零元素的, 因为要完全不存储零元素也是有代价的: 我们需要将零元素识别出来.

存储复杂度为  $O(\text{nnz} + 1)$

从上述存储格式衍生出 CSC (Compressed Sparse Column) 格式, 它包含以下三个数组:

1. `values[]`: 长度为  $\text{nnz}$ , 存储矩阵中的所有非零元素
2. `row_indices[]`: 长度为  $\text{nnz}$ , 存储与 `values[]` 中对应的每个非零元素所在的行索引
3. `col_ptr[]`: 长度为  $n + 1$ , 存储每列的起始位置.  
最后一个元素指向 `values[]` 中最后一个非零元素的后一个位置.  
(这有助于通过两个指针值相减得到对应列的非零元素个数)

若稀疏矩阵  $A$  按 CSC 格式存储, 则我们很容易开发出  $(A, x) \mapsto Ax$  和  $(A, x) \mapsto A^T x$  的程序.  
但其效率很糟糕, 因为间接寻址是低效的.

其中  $(A, x) \mapsto Ax$  操作是最重要的.

根据 Cayley-Hamilton 定理可知  $A^{-1}$  可以表示为  $A$  的  $n - 1$  次多项式  $p(A) = \sum_{i=0}^{n-1} c_i A^i$

因此  $x = A^{-1}b$  可以写成  $x = p(A)b = \sum_{i=0}^{n-1} c_i A^i b$

任意复方阵都满足其特征方程.

(Cayley-Hamilton 定理, Matrix Analysis 定理 2.4.3.2)

设  $p_A(t) := \det(tI_n - A)$  是  $A \in \mathbb{C}^{n \times n}$  的特征多项式, 则我们有  $p_A(A) = 0_{n \times n}$  成立.

- (Matrix Analysis 推论 2.4.3.4)

设  $A \in \mathbb{C}^{n \times n}$  非奇异

记其特征多项式  $p_A(t) = \det(tI - A) = t^n + c_{n-1}t^{n-1} + \dots + c_1t + c_0$

根据 Cayley-Hamilton 定理我们有  $p_A(A) = A^n + c_{n-1}A^{n-1} + \dots + c_1A + c_0I_n = 0_{n \times n}$

则  $A^{-1} = -\frac{1}{c_0}(A^{n-1} + c_{n-1}A^{n-2} + \dots + c_2A + c_1)$

考虑如下稀疏矩阵:

$$A = \begin{bmatrix} 0 & 1 & & & \\ 1 & 0 & 1 & & \\ & \ddots & \ddots & \ddots & \\ & & 1 & 0 & 1 \\ & & & 1 & 0 \end{bmatrix}_{n \times n}$$

根据高等线性代数 Homework 07 Problem 04 的结果可知其特征值和单位特征向量为:

$$\lambda_k = 2 \cos\left(\frac{k\pi}{n+1}\right) \quad x^{(k)} = \sqrt{\frac{2}{n+1}} \begin{bmatrix} \sin\left(\frac{k\pi}{n+1}\right) \\ \sin\left(\frac{2k\pi}{n+1}\right) \\ \vdots \\ \sin\left(\frac{(n-1)k\pi}{n+1}\right) \\ \sin\left(\frac{nk\pi}{n+1}\right) \end{bmatrix} \quad (k = 1, \dots, n)$$

显然  $A$  的谱分解  $A = U \Lambda U^H$  中特征矩阵  $U \in \mathbb{C}^{n \times n}$  是稠密矩阵.

因此直接对  $A$  求谱分解是不可行的.

但我们可以进行幂法迭代, 收敛出前几个特征值和特征向量 (Google 通过这种方法计算最大的特征值)  
(实际应用中我们可以有其他方法)

常用的稀疏矩阵资源网站:

- [Matrix Market](#)
- [SuiteSparse Matrix Collection \(by Tim Davis\)](#)

### 3.0.2 一维 Poisson 方程

考虑一维 Poisson 方程:

$$-\frac{d^2}{dx^2}u(x) = f(x) \quad (0 < x < 1)$$

其中初值为  $u(0) = u(1) = 0$  (即 Dirichlet 边界条件)

我们使用有限差分去逼近上述方程:

$$\begin{aligned} h &:= \frac{1}{n+1} \\ \frac{d}{dx}u(x)|_{x=(i-0.5)h} &\approx \frac{u_i - u_{i-1}}{h} \quad (i = 1, \dots, n) \\ \frac{d}{dx}u(x)|_{x=(i+0.5)h} &\approx \frac{u_{i+1} - u_i}{h} \quad (i = 1, \dots, n) \end{aligned}$$

将上述近似式相减并除以  $h$  便得到中心差分近似:

$$-\frac{d^2}{dx^2}u(x)|_{x=x_i} = \frac{2u_i - u_{i-1} - u_{i+1}}{h^2} + O\left(h^2 \cdot \left\| \frac{d^4}{dx^4}u(x) \right\|_\infty\right) \quad (i = 1, \dots, n)$$

为求解上述方程, 我们丢弃截断误差, 将其改写为:

$$\begin{aligned} -u_{i-1} + 2u_i - u_{i+1} &= h^2 f_i \quad (i = 1, \dots, n) \\ \Leftrightarrow \\ T_n u &= \begin{bmatrix} 2 & -1 & & & \\ -1 & \ddots & \ddots & & \\ & \ddots & \ddots & -1 & \\ & & -1 & 2 & \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix} = h^2 \begin{bmatrix} f_1 \\ f_2 \\ \vdots \\ f_n \end{bmatrix} = h^2 f \end{aligned}$$

(应用数值线性代数, 引理 6.1)

对称正定三对角阵  $T_n$  的特征值和单位特征向量为:

$$\lambda_k = 2 \left( 1 - \cos \left( \frac{k}{n+1} \pi \right) \right) \quad x^{(k)} = \sqrt{\frac{2}{n+1}} \begin{bmatrix} \sin \left( \frac{k\pi}{n+1} \right) \\ \sin \left( \frac{2k\pi}{n+1} \right) \\ \vdots \\ \sin \left( \frac{(n-1)k\pi}{n+1} \right) \\ \sin \left( \frac{n k \pi}{n+1} \right) \end{bmatrix} \quad (k = 1, \dots, n)$$

以  $n = 21$  的情况为例:

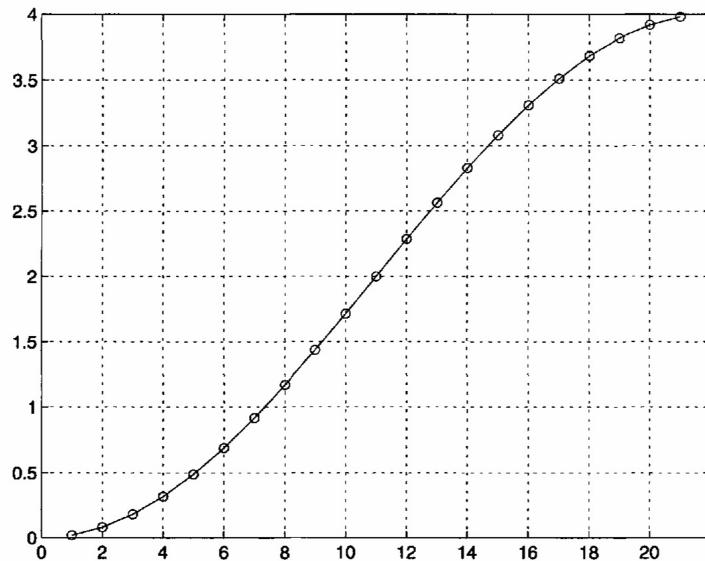


Fig. 6.1. Eigenvalues of  $T_{21}$ .

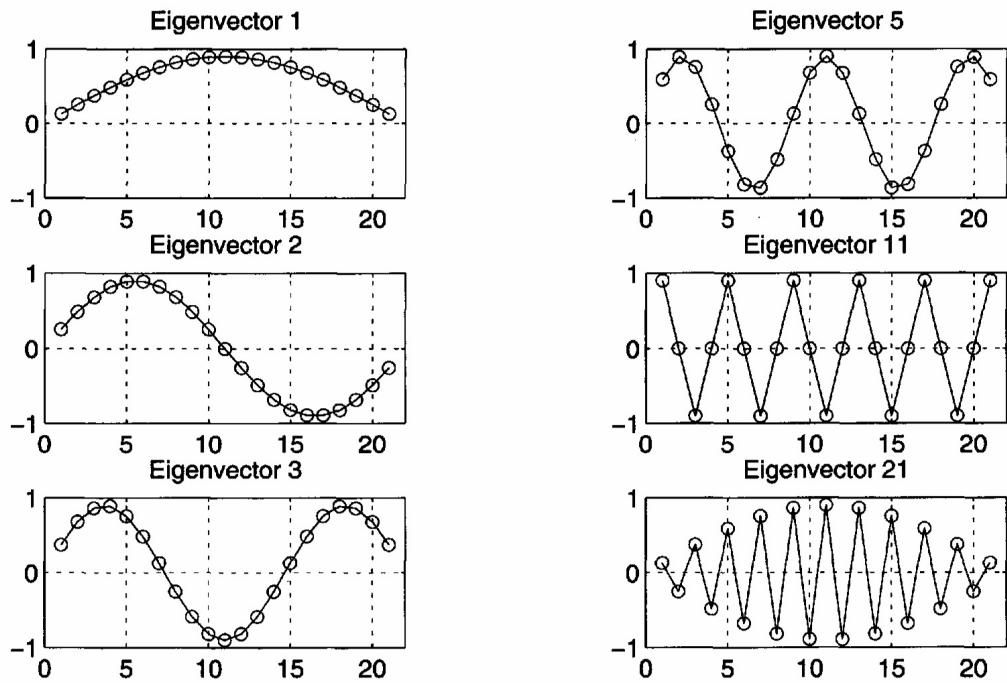


Fig. 6.2. Eigenvectors of  $T_{21}$ .

(应用数值线性代数, 习题 6.2)

$T_n$  的 Cholesky 分解和 LU 分解具有简单形式:

- $T_n$  的 Cholesky 分解  $T_n := L_n L_n^T$  中的  $L_n$  是下双对角阵:

$$L_n(i, i) = \sqrt{\frac{i+1}{i}} \quad (i = 1, \dots, n)$$

$$L_n(i+1, i) = \sqrt{\frac{i}{i+1}} \quad (i = 1, \dots, n-1)$$

- $T_n$  的 Gauss 消去法的结果  $T_n := L_n U_n$  中的  $L_n$  是单位下双对角阵, 而  $U_n$  是上双对角阵:

$$L_n(i, i) = 1 \quad (i = 1, \dots, n)$$

$$L_n(i+1, i) = -\frac{i}{i+1} \quad (i = 1, \dots, n-1)$$


---


$$U_n(i, i) = \frac{i+1}{i} \quad (i = 1, \dots, n)$$

$$U_n(i, i+1) = -1 \quad (i = 1, \dots, n-1)$$

### 3.0.3 二维 Poisson 方程

现在转向二维 Poisson 方程:

$$-\frac{\partial^2}{\partial x^2} u(x, y) - \frac{\partial^2}{\partial y^2} u(x, y) = f(x, y) \quad (0 < x, y < 1)$$

其中初值为  $\begin{cases} u(x, 0) = u(x, 1) = 0 & (\forall 0 \leq x \leq 1) \\ u(0, y) = u(1, y) = 0 & (\forall 0 \leq y \leq 1) \end{cases}$  (即 Dirichlet 边界条件)

结合一维 Poisson 方程的结论, 我们可以使用有限差分去逼近上述方程: (存疑: 似乎反了)

$$\begin{aligned} h &:= \frac{1}{n+1} \\ -\frac{\partial^2}{\partial x^2} u(x, y) \Big|_{x=x_i, y=y_j} &\approx \frac{2u_{ij} - u_{i-1,j} - u_{i+1,j}}{h^2} \quad (i, j = 1, \dots, n) \\ -\frac{\partial^2}{\partial y^2} u(x, y) \Big|_{x=x_i, y=y_j} &\approx \frac{2u_{ij} - u_{i,j-1} - u_{i,j+1}}{h^2} \quad (i, j = 1, \dots, n) \end{aligned}$$

将上述近似相加得到:

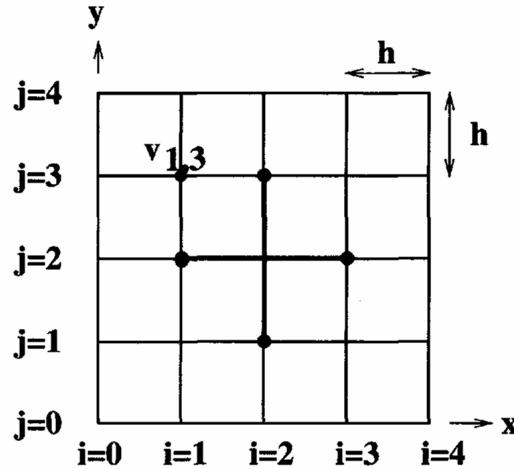
$$-\left\{ \frac{\partial^2}{\partial x^2} u(x, y) + \frac{\partial^2}{\partial y^2} u(x, y) \right\} \Big|_{x=x_i, y=y_j} \approx \frac{4u_{ij} - u_{i-1,j} - u_{i+1,j} - u_{i,j-1} - u_{i,j+1}}{h^2}$$

其中截断误差仍然是  $O(h^2)$  级别的.

于是我们得到一组具有  $n$  个未知量  $u_{ij}$  ( $1 \leq i, j \leq n$ ) 的  $n^2$  维线性方程组:

$$4u_{ij} - u_{i-1,j} - u_{i+1,j} - u_{i,j-1} - u_{i,j+1} = h^2 f_{ij} \quad (1 \leq i, j \leq n)$$

其对应的十字称为 Poisson 方程的五点型板 (stencil), 如图所示:



上述方程组具有如下紧凑形式:

$$4u_{ij} - u_{i-1,j} - u_{i+1,j} - u_{i,j-1} - u_{i,j+1} = h^2 f_{ij} \quad (1 \leq i, j \leq n)$$

$$u_{i,0} = u_{i,n+1} = u_{0,j} = u_{n+1,j} = 0 \quad (i, j = 1, \dots, n)$$

⇓

$$T_n U + U T_n = h^2 F$$

$$T_n = \begin{bmatrix} 2 & -1 & & & \\ -1 & \ddots & \ddots & & \\ & \ddots & \ddots & -1 & \\ & & -1 & 2 & \end{bmatrix} \quad U = \begin{bmatrix} u_{1,1} & u_{1,2} & \cdots & u_{1,n} \\ u_{2,1} & u_{2,2} & \cdots & u_{2,n} \\ \vdots & \vdots & & \vdots \\ u_{n,1} & u_{n,2} & \cdots & u_{n,n} \end{bmatrix} \quad F = \begin{bmatrix} f_{1,1} & f_{1,2} & \cdots & f_{1,n} \\ f_{2,1} & f_{2,2} & \cdots & f_{2,n} \\ \vdots & \vdots & & \vdots \\ f_{n,1} & f_{n,2} & \cdots & f_{n,n} \end{bmatrix}$$

⇓

$$T_{n \times n} \text{vec}(U) = h^2 \text{vec}(F)$$

$$\text{where } T_{n \times n} := (I_n \otimes T_n + T_n \otimes I_n) = \begin{bmatrix} T_n & & & \\ & \ddots & & \\ & & \ddots & \\ & & & T_n \end{bmatrix} + \begin{bmatrix} 2I_n & -I_n & & \\ -I_n & \ddots & \ddots & \\ & \ddots & \ddots & -I_n \\ & & -I_n & 2I_n \end{bmatrix}$$

以  $n = 3$  的情况为例:

$$T_{n \times n} \text{vec}(U) = \left[ \begin{array}{ccc|cc|c} 4 & -1 & -1 & -1 & & \\ -1 & 4 & -1 & -1 & -1 & \\ -1 & 4 & & & & \\ \hline -1 & & 4 & -1 & -1 & \\ -1 & & -1 & 4 & -1 & \\ -1 & & -1 & 4 & & \\ \hline & & -1 & 4 & -1 & \\ & & -1 & -1 & 4 & \\ & & & -1 & 4 & \\ \hline & & & -1 & -1 & 4 \end{array} \right] \left[ \begin{array}{c} u_{1,1} \\ u_{2,1} \\ u_{3,1} \\ u_{1,2} \\ u_{2,2} \\ u_{3,2} \\ u_{1,3} \\ u_{2,3} \\ u_{3,3} \end{array} \right] = h^2 \left[ \begin{array}{c} f_{1,1} \\ f_{2,1} \\ f_{3,1} \\ f_{1,2} \\ f_{2,2} \\ f_{3,2} \\ f_{1,3} \\ f_{2,3} \\ f_{3,3} \end{array} \right] = h^2 \text{vec}(F)$$

(存疑) 当边界条件不是 Dirichlet 边界条件时, 我们只需在等式右端引入一个边界条件矩阵  $B$  即可:

(参考 Homework 13 Problem 3)

$$4u_{ij} - u_{i-1,j} - u_{i+1,j} - u_{i,j-1} - u_{i,j+1} = h^2 f_{ij} \quad (1 \leq i, j \leq n)$$

$\Updownarrow$

$$T_n U + U T_n = h^2 F + B$$

$$T_n = \begin{bmatrix} 2 & -1 & & & \\ -1 & \ddots & \ddots & & \\ & \ddots & \ddots & -1 & \\ & & -1 & 2 & \end{bmatrix} \quad U = \begin{bmatrix} u_{1,1} & u_{1,2} & \cdots & u_{1,n} \\ u_{2,1} & u_{2,2} & \cdots & u_{2,n} \\ \vdots & \vdots & & \vdots \\ u_{n,1} & u_{n,2} & \cdots & u_{n,n} \end{bmatrix} \quad F = \begin{bmatrix} f_{1,1} & f_{1,2} & \cdots & f_{1,n} \\ f_{2,1} & f_{2,2} & \cdots & f_{2,n} \\ \vdots & \vdots & & \vdots \\ f_{n,1} & f_{n,2} & \cdots & f_{n,n} \end{bmatrix}$$

$$B = \begin{bmatrix} u_{1,0} + u_{0,1} & u_{0,2} & \cdots & u_{0,n-1} & u_{0,n} + u_{1,n+1} \\ u_{2,0} & 0 & \cdots & 0 & u_{2,n+1} \\ \vdots & \vdots & & \vdots & \vdots \\ u_{n-1,0} & 0 & \cdots & 0 & u_{n-1,n+1} \\ u_{n,0} + u_{n+1,1} & u_{n+1,2} & \cdots & u_{n+1,n-1} & u_{n+1,n} + u_{n,n+1} \end{bmatrix}$$

$$\Updownarrow$$

$$T_{n \times n} \text{vec}(U) = h^2 \text{vec}(F) + \text{vec}(B)$$

$$\text{where } T_{n \times n} := (I_n \otimes T_n + T_n \otimes I_n) = \begin{bmatrix} T_n & & & \\ & \ddots & & \\ & & \ddots & \\ & & & T_n \end{bmatrix} + \begin{bmatrix} 2I_n & -I_n & & \\ -I_n & \ddots & \ddots & \\ & \ddots & \ddots & -I_n \\ & & -I_n & 2I_n \end{bmatrix}$$

系数矩阵  $T_{n \times n} := (I_n \otimes T_n + T_n \otimes I_n)$  是  $n^2$  阶方阵, 它具有以下性质:

- 若  $U$  中顶点排列次序发生改变, 则  $T_{n \times n}$  的性状也会发生改变, 但可以证明  $T_{n \times n}$  的特征值仍旧不变.
- $T_{n \times n}$  是块三对角阵, 若不看分块的话, 共有五条对角线上有非零元素 (因此  $T_{n \times n}$  是稀疏的)
- $T_{n \times n}$  是不可约对角占优的.
- $T_{n \times n}$  是对称正定的.

回忆起对称正定三对角阵  $T_n$  的特征值和单位特征向量为:

$$\lambda_k = 2 \left( 1 - \cos \left( \frac{k}{n+1} \pi \right) \right) \quad x^{(k)} = \sqrt{\frac{2}{n+1}} \begin{bmatrix} \sin \left( \frac{k\pi}{n+1} \right) \\ \sin \left( \frac{2k\pi}{n+1} \right) \\ \vdots \\ \sin \left( \frac{(n-1)k\pi}{n+1} \right) \\ \sin \left( \frac{nk\pi}{n+1} \right) \end{bmatrix} \quad (k = 1, \dots, n)$$

因此  $T_{n \times n} := (I_n \otimes T_n + T_n \otimes I_n)$  的特征值为  $\lambda_{p,q} = 1 \cdot \lambda_p + \lambda_q \cdot 1 = 2(2 - \cos \frac{p\pi}{n} - \cos \frac{q\pi}{n})$

对应的单位特征向量为  $z^{(p,q)} = \text{vec}(x^{(p)}(x^{(q)})^\top)$

即矩阵  $x^{(p)}(x^{(q)})^\top$  按列 "拉直" 得到的  $n^2$  维向量:

$$z^{(p,q)} = \text{vec}(x^{(p)}(x^{(q)})^T) = \sqrt{\frac{2}{n+1}} \begin{bmatrix} \sin\left(\frac{k\pi}{n+1}\right)x^{(p)} \\ \sin\left(\frac{2k\pi}{n+1}\right)x^{(p)} \\ \vdots \\ \sin\left(\frac{(n-1)k\pi}{n+1}\right)x^{(p)} \\ \sin\left(\frac{nk\pi}{n+1}\right)x^{(p)} \end{bmatrix}$$

以  $n = 10$  为例:

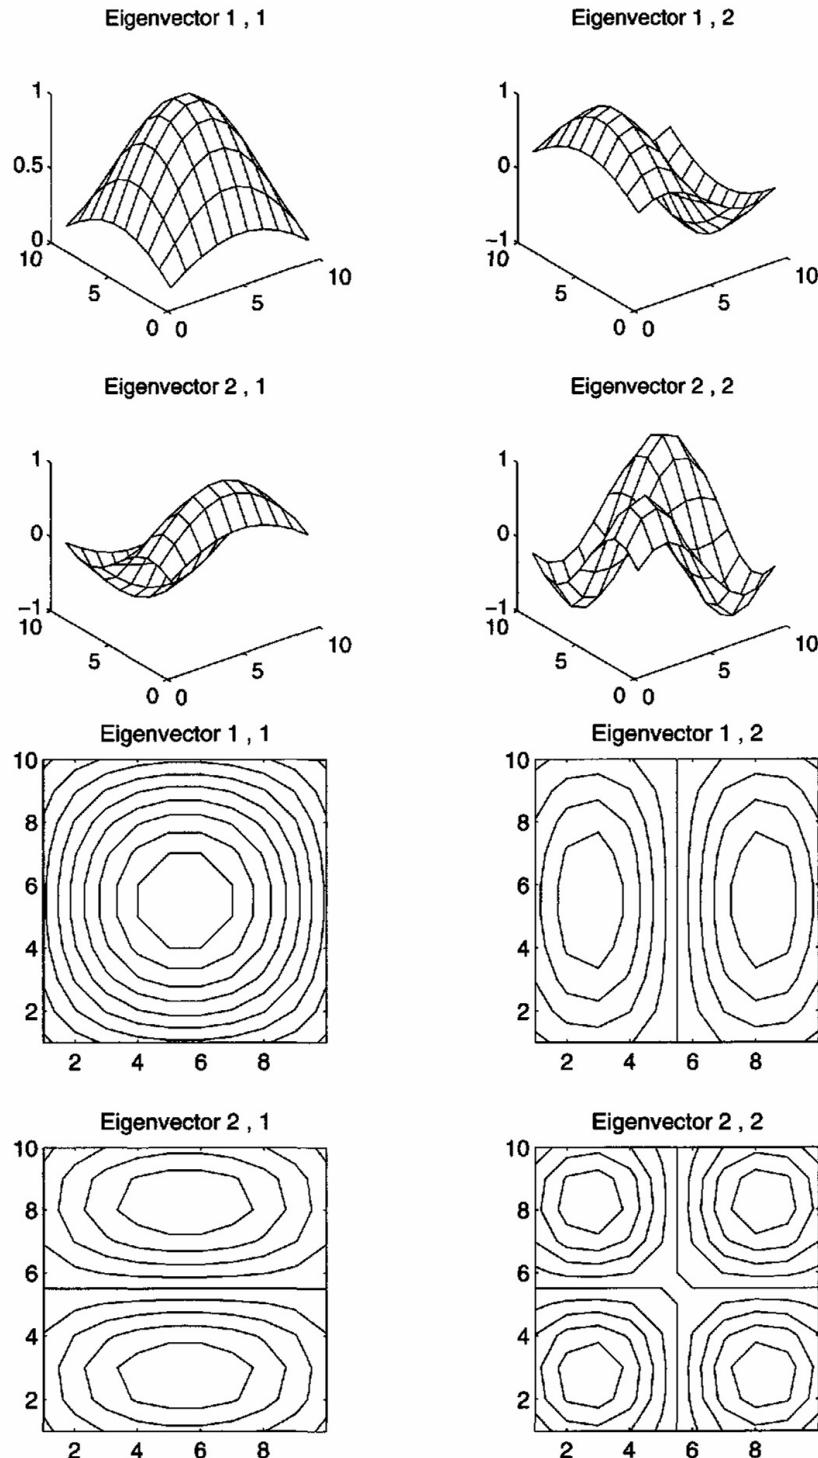


Fig. 6.3. Three-dimensional and contour plots of first four eigenvectors of the 10-by-10 Poisson equation.

```

for i = 1 : n
    for j = 1 : n
         $u_{i,j}^{(k+1)} = \frac{1}{4}(u_{i-1,j}^{(k)} + u_{i+1,j}^{(k)} + u_{i,j-1}^{(k)} + u_{i,j+1}^{(k)} + h^2 f_{ij})$ 
    end
end

```

注意到所有的新值  $u_{i,j}^{(k+1)}$  都可以彼此独立的计算.

因此当  $u_{i,j}^{(k+1)}$  被存放在一个  $n+2$  阶矩阵  $U$  中 (这个矩阵补全了边界值) 时,

我们可以只用一条 Matlab 语句来实现上述算法.

```
U(2:n+1, 2:n+1) = 0.25 * (U(1:n, 2:n+1) + U(3:n+2, 2:n+1) + U(2:n+1, 1:n) + U(2:n+1, 3:n+2) + h^2 * F);
```

其中  $h = \frac{1}{n+1}$ , 而  $f_{i,j}$  的值存储在  $n$  阶矩阵  $F$  中.

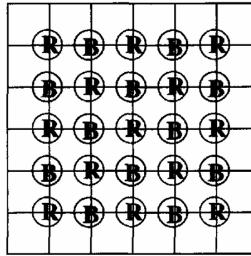
(具体实现参见 Homework 11 Problem 05)

### 红黑序:

(红节点的坐标之和为偶数, 黑节点的坐标之和为奇数)

我们首先使用来自黑节点的旧数据更新所有的红节点,

再使用来自红节点的新数据更新所有的黑节点.



于是得到如下算法:

(二维 Poisson 方程红黑序 Gauss-Seidel 法单步, 应用数值线性代数, 算法 6.4)

```

for all nodes (i, j) that are red (i.e. i + j is even)
     $u_{i,j}^{(k+1)} = \frac{1}{4}(u_{i-1,j}^{(k)} + u_{i+1,j}^{(k)} + u_{i,j-1}^{(k)} + u_{i,j+1}^{(k)} + h^2 f_{ij})$ 
end
for all nodes (i, j) that are black (i.e. i + j is odd)
     $u^{(k+1)_{i,j}} = \frac{1}{4}(u_{i-1,j}^{(k+1)} + u_{i+1,j}^{(k+1)} + u_{i,j-1}^{(k+1)} + u_{i,j+1}^{(k+1)} + h^2 f_{ij})$ 
end

```

求解二维 Poisson 问题 Gauss-Seidel 迭代更快, 其每步迭代的效果相当于 Jacobi 迭代的两步.

对于大多数经典问题来说, 都是 Gauss-Seidel 迭代更快.

(具体实现参见 Homework 11 Problem 05)

## 3.1 单步线性定常迭代法

在众多迭代法中, 最简单最基本的就是单步线性定常迭代法.

给定  $A \in \mathbb{C}^{n \times n}$ , 我们可将其拆分为:

$$A = M - N$$

其中  $M$  非奇异 (我们希望  $M \approx A$  且容易求逆)

例如使用 Toepliz 分解:

$$A := H + K = \frac{A + A^H}{2} + \frac{A - A^H}{2}$$

我们记:

$$M := H + \alpha I$$

$$N := -K + \alpha I$$

$$A := M - N$$

其中  $\alpha > 0$  为一个常数, 以保证  $M = H + \alpha I$  可逆 (但它可能不容易求逆)

于是我们有:

$$\begin{aligned} Ax &= (M - N)x = b \\ &\Downarrow \\ Mx &= b + Nx \\ &\Downarrow \\ x &= M^{-1}Nx + M^{-1}b \end{aligned}$$

我们可以据此写出单步线性定常迭代法的通用格式:

$$\begin{aligned} x^{(k+1)} &= M^{-1}Nx^{(k)} + M^{-1}b \\ &\Downarrow \\ x^{(k+1)} &= Bx^{(k)} + c \quad (\text{where } \begin{cases} B = M^{-1}N \\ c = M^{-1}b \end{cases}) \end{aligned}$$

我们首先从最简单的 Jacobi 迭代法讲起.

### 3.1.1 Jacobi 迭代法

给定  $\begin{cases} A \in \mathbb{R}^{n \times n} \\ b \in \mathbb{R}^n \end{cases}$  考虑非奇异线性方程组  $Ax = b$

我们将非奇异矩阵  $A = [a_{ij}]$  分解为:

$$A = D - L - U$$

$$D = \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{bmatrix} \quad L = \begin{bmatrix} 0 & & & \\ -a_{21} & 0 & & \\ \vdots & \ddots & \ddots & \\ -a_{n1} & \cdots & -a_{n,n-1} & 0 \end{bmatrix} \quad U = \begin{bmatrix} 0 & -a_{12} & \cdots & -a_{1n} \\ 0 & \ddots & \ddots & \vdots \\ \ddots & & -a_{n-1,n} & 0 \end{bmatrix}$$

假设  $D$  非奇异, 即  $A$  的对角元均非零, 则  $Ax = b$  可以改写为:

$$\begin{aligned} Ax &= (D - L - U)x = b \\ &\Downarrow \\ x &= D^{-1}(L + U)x + D^{-1}b \\ &\Downarrow \\ x &= Bx + c \quad \text{where } \begin{cases} B = D^{-1}(L + U) \\ c = D^{-1}b \end{cases} \end{aligned}$$

给定初始向量  $x^{(0)} = (x_1^{(0)}, \dots, x_n^{(0)})^T$

我们将  $x^{(0)}$  带入  $x = Bx + c$  的右侧, 得到  $x^{(1)} = Bx^{(0)} + c$

再将  $x^{(1)}$  带入  $x = Bx + c$  的右侧, 又可得到  $x^{(2)} = Bx^{(1)} + c$

以此类推, 我们有  $x^{(k)} = Bx^{(k-1)} + c$  ( $k = 1, 2, \dots$ )

这就是 **Jacobi 迭代法**, 其中  $B$  为迭代矩阵,  $c$  为常数项.

Jacobi 迭代法中,  $x^{(k)}$  的所有分量都由  $x^{(k-1)}$  确定, 因此先计算哪个分量都一样.

### 3.1.2 Gauss-Seidel 迭代法

现在假设不按 Jacobi 迭代格式.

记:

$$B = \begin{bmatrix} b_1^T \\ \vdots \\ b_n^T \end{bmatrix} = D^{-1}(L + U) = \begin{bmatrix} a_{11}^{-1} & & \\ & \ddots & \\ & & a_{nn}^{-1} \end{bmatrix} \left( \begin{bmatrix} l_1^T \\ \vdots \\ l_n^T \end{bmatrix} + \begin{bmatrix} u_1^T \\ \vdots \\ u_n^T \end{bmatrix} \right)$$

于是  $b_k^T = a_{kk}^{-1}(l_k^T + u_k^T)$  ( $k = 1, \dots, n$ )

回顾之前的记号:

$$A = D - L - U$$

$$D = \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{bmatrix} \quad L = \begin{bmatrix} l_1^T \\ l_2^T \\ \vdots \\ l_n^T \end{bmatrix} = \begin{bmatrix} 0 & & & \\ -a_{21} & 0 & & \\ \vdots & \ddots & \ddots & \\ -a_{n1} & \cdots & -a_{n,n-1} & 0 \end{bmatrix} \quad U = \begin{bmatrix} u_1^T \\ u_2^T \\ \vdots \\ u_n^T \end{bmatrix} = \begin{bmatrix} 0 & -a_{12} & \cdots & -a_{1n} \\ 0 & \ddots & \ddots & \vdots \\ \vdots & \ddots & -a_{n-1,n} \\ 0 & & & 0 \end{bmatrix}$$

- 计算第 1 个分量:

$$\begin{aligned} x_1^{(k)} &= b_1^T x^{(k-1)} + c_1 \\ &= a_{11}^{-1} (l_1^T + u_1^T) x^{(k-1)} + c_1 \\ &= a_{11}^{-1} u_1^T x^{(k-1)} + c_1 \quad (\text{note that } l_1 = 0_n) \\ &= a_{11}^{-1} (l_1^T x^{(k)} + u_1^T x^{(k-1)}) + c_1 \end{aligned}$$

- 在计算第 2 个分量  $x_2^{(k)}$  时, 第 1 个分量  $x_1^{(k)}$  已经算出, 于是我们可用  $x_1^{(k)}$  代替  $x_1^{(k-1)}$

$$\begin{aligned} x_2^{(k)} &= b_2^T \begin{bmatrix} x_1^{(k)} \\ x_2^{(k-1)} \\ \vdots \\ x_n^{(k-1)} \end{bmatrix} + c_2 \\ &= a_{22}^{-1} (l_2^T + u_2^T) \begin{bmatrix} x_1^{(k)} \\ x_2^{(k-1)} \\ \vdots \\ x_n^{(k-1)} \end{bmatrix} + c_2 \\ &= a_{22}^{-1} ([-a_{21}, 0, 0, \dots, 0] + [0, 0, -a_{23}, \dots, -a_{2n}]) \begin{bmatrix} x_1^{(k)} \\ x_2^{(k-1)} \\ \vdots \\ x_n^{(k-1)} \end{bmatrix} + c_2 \\ &= a_{22}^{-1} \left( \begin{bmatrix} x_1^{(k)} \\ x_2^{(k)} \\ \vdots \\ x_n^{(k)} \end{bmatrix} + [0, 0, -a_{23}, \dots, -a_{2n}] \begin{bmatrix} x_1^{(k-1)} \\ x_2^{(k-1)} \\ \vdots \\ x_n^{(k-1)} \end{bmatrix} \right) + c_2 \\ &= a_{22}^{-1} (l_2^T x^{(k)} + u_2^T x^{(k-1)}) + c_2 \end{aligned}$$

- 以此类推, 在计算第  $m$  个分量  $x_l^{(k)}$  时, 第 1 个分量至第  $m-1$  个分量  $x_1^{(k)}, \dots, x_{m-1}^{(k)}$  已经算出, 于是我们可用  $x_1^{(k)}, \dots, x_{m-1}^{(k)}$  代替  $x_1^{(k-1)}, \dots, x_{m-1}^{(k-1)}$

$$\begin{aligned}
x_m^{(k)} &= b_m^T \begin{bmatrix} x_1^{(k)} \\ \vdots \\ x_{m-1}^{(k)} \\ x_m^{(k-1)} \\ \vdots \\ x_n^{(k-1)} \end{bmatrix} + c_m \\
&= a_{mm}^{-1}(l_m^T + u_m^T) \begin{bmatrix} x_1^{(k)} \\ \vdots \\ x_{m-1}^{(k)} \\ x_m^{(k-1)} \\ \vdots \\ x_n^{(k-1)} \end{bmatrix} + c_m \\
&= a_{mm}^{-1}([-a_{m1}, \dots, -a_{m,m-1}, 0, 0, \dots, 0] + [0, \dots, 0, 0, -a_{m,m+1}, \dots, -a_{m,n}]) \begin{bmatrix} x_1^{(k)} \\ \vdots \\ x_{m-1}^{(k)} \\ x_m^{(k-1)} \\ \vdots \\ x_n^{(k-1)} \end{bmatrix} + c_m \\
&= a_{mm}^{-1} \left( \begin{bmatrix} x_1^{(k)} \\ \vdots \\ x_{m-1}^{(k)} \\ x_m^{(k-1)} \\ \vdots \\ x_n^{(k-1)} \end{bmatrix} + [-a_{m1}, \dots, -a_{m,m-1}, 0, 0, \dots, 0] + [0, \dots, 0, 0, -a_{m,m+1}, \dots, -a_{m,n}] \right) + c_m \\
&= a_{mm}^{-1}(l_m^T x^{(k)} + u_m^T x^{(k-1)}) + c_m
\end{aligned}$$

综上所述，我们得到：

$$\begin{cases} x_1^{(k)} = a_{11}^{-1}(l_1^T x^{(k)} + u_1^T x^{(k-1)}) + c_1 \\ \vdots \\ x_n^{(k)} = a_{nn}^{-1}(l_n^T x^{(k)} + u_n^T x^{(k-1)}) + c_n \end{cases} \Downarrow x^{(k)} = D^{-1}(Lx^{(k)} + Ux^{(k-1)}) + c = D^{-1}(Lx^{(k)} + Ux^{(k-1)}) + D^{-1}b$$

由于我们假设  $D$  非奇异 (对角元均非零)，故  $D - L$  也是非奇异的。

因此上式可改写为  $x^{(k)} = (D - L)^{-1}Ux^{(k-1)} + (D - L)^{-1}b$  ( $k = 1, 2, \dots$ )

这就是 **Gauss-Seidel 迭代法**。

我们称  $(D - L)^{-1}U$  为 G-S 迭代法的迭代矩阵，而  $(D - L)^{-1}b$  为常数项。

### 3.1.3 单步线性定常迭代法

考虑非奇异线性方程组  $Ax = b$ ，假设  $A$  的对角元均非零。

回顾之前的记号：

$$A = D - L - U$$

$$D = \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{bmatrix} \quad L = \begin{bmatrix} 0 & & & \\ -a_{21} & 0 & & \\ \vdots & \ddots & \ddots & \\ -a_{n1} & \cdots & -a_{n,n-1} & 0 \end{bmatrix} \quad U = \begin{bmatrix} 0 & -a_{12} & \cdots & -a_{1n} \\ 0 & \ddots & & \vdots \\ \ddots & & -a_{n-1,n} \\ & & & 0 \end{bmatrix}$$

$$\text{对比 Jacobi 迭代格式和 Gauss-Seidel 迭代格式} \begin{cases} x^{(k)} = D^{-1}(L+U)x^{(k-1)} + D^{-1}b \\ x^{(k)} = (D-L)^{-1}Ux^{(k-1)} + (D-L)^{-1}b \end{cases}$$

我们发现它们有一个共同点:

**新近似解  $x^{(k)}$  是已知近似解  $x^{(k-1)}$  的线性函数, 且仅与  $x^{(k-1)}$  有关, 与其他已知近似解无关.**

即它们可以抽象成  $x^{(k)} = Bx^{(k-1)} + c$  的形式,

$$\text{对于 Jacobi 迭代法有 } \begin{cases} B = D^{-1}(L+U) \\ c = D^{-1}b \end{cases}, \text{ 对于 Gauss-Seidel 迭代法有 } \begin{cases} B = (D-L)^{-1}U \\ c = (D-L)^{-1}b \end{cases}$$

我们称形如  $x^{(k)} = Bx^{(k-1)} + c$  的迭代法为**单步线性定常迭代法**.

若对于任意初始向量  $x^{(0)}$ , 该迭代格式产生的向量序列  $\{x^{(k)}\}$  都有极限, 则称该迭代法收敛;

否则我们称它是发散的.

- 若迭代法收敛, 并记其极限为  $x^*$ ,

则对  $x^{(k)} = Bx^{(k-1)} + c$  两侧同时取极限, 即得到  $x^* = Bx^* + c$

表明  $x^*$  恰为方程组  $x = Bx + c$  的解.

对于充分大的  $k$ ,  $x^{(k)}$  便可作为  $x = Bx + c$  的近似解.

- 进一步, 若方程组  $x = Bx + c$  和原方程组  $Ax = b$  等价,

即存在非奇异矩阵  $G \in \mathbb{R}^{n \times n}$  使得  $\begin{cases} A = G(I_n - B) \\ b = Gc \end{cases}$  (此时称迭代法与  $Ax = b$  相容),

则迭代法的极限  $x^*$  也是非奇异线性方程组  $Ax = b$  的唯一解.

此时, 对于充分大的  $k$ ,  $x^{(k)}$  便可作为  $Ax = b$  的近似解.

从实用角度来讲, 我们只对相容的收敛迭代法感兴趣.

显然对于任意一个满足 "A 对角元均非零" 的非奇异线性方程组  $Ax = b$ ,

Jacobi 迭代法和 Gauss-Seidel 迭代法都与之相容.

但它们的收敛条件是什么呢?

## 3.2 收敛性理论

### 3.2.1 收敛的充要条件

设  $x^*$  是非奇异线性方程组  $Ax = b$  的精确解.

考虑与  $Ax = b$  相容的单步线性定常迭代法  $x^{(k)} = Bx^{(k-1)} + c$  产生的迭代序列  $\{x^{(k)}\}$

若该迭代法收敛, 则其极限  $x^*$  满足  $x^* = Bx^* + c$

定义  $x^{(k)}$  误差向量为  $e^{(k)} = x^{(k)} - x^*$

$$\text{联立 } \begin{cases} x^{(k)} = Bx^{(k-1)} + c \\ x^* = Bx^* + c \\ e^{(k)} = x^{(k)} - x^* \\ e^{(k-1)} = x^{(k-1)} - x^* \end{cases} \text{ 可得 } e^{(k)} = B \cdot e^{(k-1)} \quad (k = 1, 2, \dots)$$

于是我们有  $e^{(k)} = B^k e^{(0)} \quad (k = 1, 2, \dots)$

因此  $\lim_{k \rightarrow \infty} x^{(k)} = x^*$  (即  $\lim_{k \rightarrow \infty} e^{(k)} = 0_n$ ) 的充要条件是  $\lim_{k \rightarrow \infty} B^k = O_{n \times n}$

- (**数值线性代数, 引理 4.2.1**)

单步线性定常迭代法  $x^{(k)} = Bx^{(k-1)} + c$  收敛的充要条件是  $\lim_{k \rightarrow \infty} B^k = 0_{n \times n}$

- 定义  $A \in \mathbb{C}^{n \times n}$  的谱半径为  $\rho(A) := \max_{1 \leq i \leq n} |\lambda_i(A)|$

(**数值线性代数, 定理 2.1.7**)

对于任意  $A \in \mathbb{C}^{n \times n}$ , 当且仅当  $\rho(A) < 1$  时  $\lim_{k \rightarrow \infty} A^k = 0_{n \times n}$

也就是说, 当且仅当  $\rho(A) < 1$  时 Neumann 级数  $\sum_{k=0}^{\infty} A^k$  收敛 (且收敛到  $(I - A)^{-1}$ )

- 结合上述两个定理, 我们有:

(**数值线性代数, 定理 4.2.1**)

单步线性定常迭代法  $x^{(k)} = Bx^{(k-1)} + c$  收敛的充要条件是  $\rho(B) < 1$

这表明迭代序列  $\{x^{(k)}\}$  的收敛性仅取决于迭代矩阵  $B$  的谱半径,

而与初始向量  $\{x^{(0)}\}$  的选取和常数项  $c$  无关.

---

考虑一个满足 "A 对角元均非零" 的非奇异线性方程组  $Ax = b$

回顾之前的记号:

$$A = D - L - U$$

$$D = \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{bmatrix} \quad L = \begin{bmatrix} 0 & & & \\ -a_{21} & 0 & & \\ \vdots & \ddots & \ddots & \\ -a_{n1} & \cdots & -a_{n,n-1} & 0 \end{bmatrix} \quad U = \begin{bmatrix} 0 & -a_{12} & \cdots & -a_{1n} \\ 0 & \ddots & \ddots & \vdots \\ \vdots & & -a_{n-1,n} & \\ 0 & & & 0 \end{bmatrix}$$

Jacobi 迭代矩阵  $D^{-1}(L + U)$  和 Gauss-Seidel 迭代矩阵  $(D - L)^{-1}U$  的谱半径之间并无直接联系.

因此, 有时 Jacobi 迭代法收敛而 Gauss-Seidel 迭代法发散,

有时 Gauss-Seidel 迭代法收敛而 Jacobi 迭代法发散, 有时它们都收敛, 有时它们都发散.

- 考虑以下方阵:

$$A = \begin{bmatrix} 1 & 2 & -2 \\ 1 & 1 & 1 \\ 2 & 2 & 1 \end{bmatrix}$$

此时我们有:

$$D = \begin{bmatrix} 1 & & \\ & 1 & \\ & & 1 \end{bmatrix} \quad L = \begin{bmatrix} 0 & & \\ -1 & 0 & \\ -2 & -2 & 0 \end{bmatrix} \quad U = \begin{bmatrix} 0 & -2 & 2 \\ 0 & 0 & -1 \\ 0 & 0 & 0 \end{bmatrix}$$

Jacobi 迭代矩阵为:

$$B_{\text{Jacobi}} := D^{-1}(L + U) = \begin{bmatrix} 1 & & \\ & 1 & \\ & & 1 \end{bmatrix}^{-1} \begin{bmatrix} 0 & -2 & 2 \\ -1 & 0 & -1 \\ -2 & -2 & 0 \end{bmatrix} = \begin{bmatrix} 0 & -2 & 2 \\ -1 & 0 & -1 \\ -2 & -2 & 0 \end{bmatrix}$$

其特征多项式为  $\lambda^3$ , 特征值为  $0, 0, 0$ , 谱半径  $\rho(B_{\text{Jacobi}}) = 0 < 1$

因此 Jacobi 迭代法收敛.

Gauss-Seidel 迭代矩阵为:

$$B_{\text{G-S}} := (D - L)^{-1}U = \begin{bmatrix} 1 & & \\ 1 & 1 & \\ 2 & 2 & 1 \end{bmatrix}^{-1} \begin{bmatrix} 0 & -2 & 2 \\ 0 & -1 & \\ 0 & 0 & \end{bmatrix} = \begin{bmatrix} 1 & & \\ -1 & 1 & \\ -2 & 1 & \end{bmatrix} \begin{bmatrix} 0 & -2 & 2 \\ 0 & -1 & \\ 0 & 0 & \end{bmatrix} = \begin{bmatrix} 0 & -2 & 2 \\ 2 & -3 & \\ 2 & 2 & \end{bmatrix}$$

其特征多项式为  $\lambda(\lambda - 2)^2$ , 特征值为  $0, 2, 2$ , 谱半径  $\rho(B_{\text{G-S}}) = 2 \geq 1$

因此 Gauss-Seidel 迭代发散.

- 考虑以下方阵:

$$A = \begin{bmatrix} 2 & -1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & -2 \end{bmatrix}$$

此时我们有:

$$D = \begin{bmatrix} 2 & & \\ & 1 & \\ & & -2 \end{bmatrix} \quad L = \begin{bmatrix} 0 & & \\ -1 & 0 & \\ -1 & -1 & 0 \end{bmatrix} \quad U = \begin{bmatrix} 0 & 1 & -1 \\ 0 & 0 & -1 \\ 0 & 0 & 0 \end{bmatrix}$$

Jacobi 迭代矩阵为:

$$B_{\text{Jacobi}} := D^{-1}(L + U) = \begin{bmatrix} 2 & & \\ & 1 & \\ & & -2 \end{bmatrix}^{-1} \begin{bmatrix} 0 & 1 & -1 \\ -1 & 0 & -1 \\ -1 & -1 & 0 \end{bmatrix} = \begin{bmatrix} 0 & \frac{1}{2} & -\frac{1}{2} \\ -1 & 0 & -1 \\ \frac{1}{2} & \frac{1}{2} & 0 \end{bmatrix}$$

其特征多项式为  $\lambda(\lambda^2 + \frac{5}{4})$ , 特征值为  $0, \pm \frac{\sqrt{5}}{2}i$ , 谱半径  $\rho(B_{\text{Jacobi}}) := \frac{\sqrt{5}}{2} \geq 1$

因此 Jacobi 迭代法发散.

Gauss-Seidel 迭代矩阵为:

$$B_{\text{G-S}} := (D - L)^{-1}U = \begin{bmatrix} 2 & & \\ 1 & 1 & \\ 1 & 1 & -2 \end{bmatrix}^{-1} \begin{bmatrix} 0 & 1 & -1 \\ 0 & -1 & \\ 0 & 0 & \end{bmatrix} = \begin{bmatrix} \frac{1}{2} & & \\ -\frac{1}{2} & 1 & \\ 0 & \frac{1}{2} & -\frac{1}{2} \end{bmatrix} \begin{bmatrix} 0 & 1 & -1 \\ 0 & -1 & \\ 0 & 0 & \end{bmatrix} = \begin{bmatrix} 0 & \frac{1}{2} & -\frac{1}{2} \\ -\frac{1}{2} & -\frac{1}{2} & \\ -\frac{1}{2} & -\frac{1}{2} & \end{bmatrix}$$

其特征多项式为  $\lambda(\lambda + \frac{1}{2})^2$ , 特征值为  $0, \frac{1}{2}, \frac{1}{2}$ , 谱半径  $\rho(B_{G-S}) = \frac{1}{2} < 1$   
因此 Gauss-Seidel 迭代收敛.

### 3.2.2 误差估计

设  $x^*$  是非奇异线性方程组  $Ax = b$  的精确解.

考虑与  $Ax = b$  相容的单步线性定常迭代法  $x^{(k)} = Bx^{(k-1)} + c$  产生的迭代序列  $\{x^{(k)}\}$

(数值线性代数, 定理 4.2.2)

若迭代矩阵  $B$  的范数  $\|B\| = q < 1$  (根据谱半径定理, 这保证了  $\rho(B) \leq \|B\| < 1$ , 因而迭代法收敛),  
则误差向量的范数  $\|e^{(k)}\| = \|x^{(k)} - x^*\| \leq \frac{q^k}{1-q} \|x^{(1)} - x^{(0)}\|$

- 在实际计算中, 定理中的相容范数  $\|\cdot\|$  通常选用  $\|\cdot\|_1$  或  $\|\cdot\|_\infty$  (因为它们容易计算)

- 证明: 根据之前的结论, 我们有  $e^{(k)} = B^k e^{(0)}$

两边取范数, 即有  $\|e^{(k)}\| = \|B^k e^{(0)}\| \leq \|B\|^k \cdot \|e^{(0)}\| = q^k \|e^{(0)}\|$

下面估计  $\|e^{(0)}\|$ :

$$\begin{aligned}\|e^{(0)}\| &= \|x^{(0)} - x^*\| \\ &= \|x^{(0)} - x^{(1)} + x^{(1)} - x^*\| \\ &\leq \|x^{(0)} - x^{(1)}\| + \|x^{(1)} - x^*\| \\ &= \|x^{(0)} - x^{(1)}\| + \|Be^{(0)}\| \quad (\text{note that } \|x^{(1)} - x^*\| = \|e^{(1)}\| = \|Be^{(0)}\| \leq \|B\| \|e^{(0)}\| = q \|e^{(0)}\|) \\ &\leq \|x^{(1)} - x^{(0)}\| + q \|e^{(0)}\|\end{aligned}$$

于是有  $\|e^{(0)}\| \leq \frac{1}{1-q} \|x^{(1)} - x^{(0)}\|$

因此  $\|e^{(k)}\| \leq q^k \|e^{(0)}\| \leq \frac{q^k}{1-q} \|x^{(1)} - x^{(0)}\|$ , 命题得证.

上述定理给出的误差估计往往偏高, 在实际计算时用它控制迭代次数的效果并不好.

所以给出下面的定理:

(数值线性代数, 定理 4.2.3)

若迭代矩阵  $B$  的范数  $\|B\| = q < 1$  (根据谱半径定理, 这保证了  $\rho(B) \leq \|B\| < 1$ , 因而迭代法收敛),  
则误差向量的范数  $\|e^{(k)}\| = \|x^{(k)} - x^*\| \leq \frac{q}{1-q} \|x^{(k)} - x^{(k-1)}\|$

- 证明:

$$\begin{aligned}\|e^{(k)}\| &= \|Be^{(k-1)}\| \\ &\leq \|B\| \|e^{(k-1)}\| \\ &= q \|e^{(k-1)}\| \\ &= q \|x^{(k-1)} - x^*\| \\ &\leq q (\|x^{(k-1)} - x^{(k)}\| + \|x^{(k)} - x^*\|) \\ &= q \|x^{(k)} - x^{(k-1)}\| + q \|e^{(k)}\|\end{aligned}$$

于是有  $\|e^{(k)}\| \leq \frac{q}{1-q} \|x^{(k)} - x^{(k-1)}\|$ , 命题得证.

- 上述定理表明: 在  $\|B\| = q < 1$  的前提条件下,  
当相邻两次的迭代解  $x^{(k-1)}$  和  $x^{(k)}$  很接近时,  $x^{(k)}$  与精确解  $x^*$  也很接近.  
在实际计算中, 这个误差估计用来控制迭代次数 (构造终止条件) 是非常方便的.

### 3.2.3 Jacobi 迭代法和 Gauss-Seidel 迭代法的收敛性

考虑一个满足 "A 对角元均非零" 的非奇异线性方程组  $Ax = b$

回顾之前的记号:

$$A = D - L - U$$

$$D = \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{bmatrix} \quad L = \begin{bmatrix} 0 & & & \\ -a_{21} & 0 & & \\ \vdots & \ddots & \ddots & \\ -a_{n1} & \cdots & -a_{n,n-1} & 0 \end{bmatrix} \quad U = \begin{bmatrix} 0 & -a_{12} & \cdots & -a_{1n} \\ 0 & \ddots & & \vdots \\ \ddots & & \ddots & -a_{n-1,n} \\ & & & 0 \end{bmatrix}$$

Jacobi 迭代矩阵  $D^{-1}(L + U)$  和 Gauss-Seidel 迭代矩阵  $(D - L)^{-1}U$  的谱半径之间并无直接联系，但是它们的范数之间有一些联系.

考虑到 Jacobi 迭代矩阵  $D^{-1}(L + U)$  要比 Gauss-Seidel 迭代矩阵  $(D - L)^{-1}U$  更容易计算，我们可以利用 Jacobi 迭代矩阵构造 Gauss-Seidel 迭代法的收敛条件，从而规避更复杂的计算.

对于 Jacobi 迭代法记  $\begin{cases} B^{(1)} = D^{-1}(L + U) \\ c^{(1)} = D^{-1}b \end{cases}$ ，对于 Gauss-Seidel 迭代法记  $\begin{cases} B^{(2)} = (D - L)^{-1}U \\ c^{(2)} = (D - L)^{-1}b \end{cases}$

#### (数值线性代数, 定理 4.2.4)

若  $\|B^{(1)}\|_\infty < 1$  (这保证了 Jacobi 迭代法收敛)，

则  $\|B^{(2)}\|_\infty < 1$  (这说明了 Gauss-Seidel 迭代法也收敛)，

且 Gauss-Seidel 迭代法的误差向量的范数  $\|e^{(k)}\|_\infty = \|x^{(k)} - x^*\|_\infty \leq \frac{\mu^k}{1-\mu} \|x^{(1)} - x^{(0)}\|_\infty$

$$\text{其中 } \mu = \max_{1 \leq i \leq n} \left\{ \frac{\sum_{j=i-1}^n |b_{ij}^{(1)}|}{1 - \sum_{j=1}^{i-1} |b_{ij}^{(1)}|} \right\} \leq \|B^{(1)}\|_\infty < 1$$

#### (数值线性代数, 定理 4.2.5)

若  $\|B^{(1)}\|_1 < 1$  (这保证了 Jacobi 迭代法收敛)，

则  $\rho(B^{(2)}) < 1$  (这说明了 Gauss-Seidel 迭代法也收敛)，

且 Gauss-Seidel 迭代法的误差向量的范数  $\|e^{(k)}\|_1 = \|x^{(k)} - x^*\|_1 \leq \frac{\mu^k}{(1-\mu)(1-s)} \|x^{(1)} - x^{(0)}\|_1$

其中：

$$\mu = \max_{1 \leq j \leq n} \left\{ \frac{\sum_{i=1}^{j-1} |b_{ij}^{(1)}|}{1 - \sum_{i=j+1}^n |b_{ij}^{(1)}|} \right\} \leq \|B^{(1)}\|_1 < 1$$

$$s = \max_{1 \leq j \leq n} \left\{ \sum_{i=j+1}^n |b_{ij}^{(1)}| \right\}$$

考虑一个满足 "A 对角元均非零" 的非奇异线性方程组  $Ax = b$

若系数矩阵 A 还满足某些性质，我们还能推出一些更好的结论.

回顾之前的记号：

$$A = D - L - U$$

$$D = \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{bmatrix} \quad L = \begin{bmatrix} 0 & & & \\ -a_{21} & 0 & & \\ \vdots & \ddots & \ddots & \\ -a_{n1} & \cdots & -a_{n,n-1} & 0 \end{bmatrix} \quad U = \begin{bmatrix} 0 & -a_{12} & \cdots & -a_{1n} \\ 0 & \ddots & & \vdots \\ \ddots & & -a_{n-1,n} \\ 0 & & & \end{bmatrix}$$

#### (数值线性代数, 定理 4.2.6)

若  $A$  是对称矩阵，且对角元均为正数 (即  $a_{ii} > 0$  ( $i = 1, \dots, n$ )),

则当且仅当  $A$  和  $2D - A$  都正定时 Jacobi 迭代法收敛.

- **证明:** 记 Jacobi 迭代矩阵为  $B = D^{-1}(L + U) = D^{-1}(D - A) = I - D^{-1}A$

由于  $A$  对角元均为正数，故  $D = \text{diag}(a_{11}, \dots, a_{nn})$  是一个正定的对角阵.

我们可以定义  $D^{\frac{1}{2}} := \text{diag}(\sqrt{a_{11}}, \dots, \sqrt{a_{nn}})$

于是有  $B = I - D^{-1}A = D^{-\frac{1}{2}}(I - D^{-\frac{1}{2}}AD^{-\frac{1}{2}})D^{\frac{1}{2}}$

可以推出  $\begin{cases} I - B = D^{-\frac{1}{2}}(D^{-\frac{1}{2}}AD^{-\frac{1}{2}})D^{\frac{1}{2}} \\ I + B = D^{-\frac{1}{2}}(2I - D^{-\frac{1}{2}}AD^{-\frac{1}{2}})D^{\frac{1}{2}} \end{cases}$

因为  $A$  是对称阵，所以  $B$  也是对称阵 (因此  $B$  的特征值均为实数)

我们知道 Jacobi 迭代法收敛，当且仅当迭代矩阵  $B$  的谱半径  $\rho(B) < 1$ ,

也就等价于  $|\lambda_i(B)| < 1$  ( $i = 1, \dots, n$ )，

即等价于  $-1 < \lambda_i(B) < 1$  ( $i = 1, \dots, n$ ) (注意到  $B$  的特征值均为实数)，

即等价于  $I - B$  和  $I + B$  均正定，

即等价于  $D^{-\frac{1}{2}}AD^{-\frac{1}{2}}$  和  $2I - D^{-\frac{1}{2}}AD^{-\frac{1}{2}}$  均正定 (相似变换不改变特征值)，

即等价于  $A$  和  $2I - A$  均正定 (合同变换不改变正定性).

命题得证.

#### (数值线性代数, 定理 4.2.7)

若  $A$  对称正定，则 Gauss-Seidel 迭代法收敛.

或者更一般地，Hermite 正定矩阵  $A \in \mathbb{C}^{n \times n}$  的 Gauss-Seidel 迭代法一定收敛.

- 对于对称正定线性系统，Jacobi 迭代法并不一定收敛 (参见 Homework 11 Problem 02)  
从这个意义来说，Gauss-Seidel 迭代法要优于 Jacobi 迭代法

- 邵老师提供的证明:

考虑 Hermite 正定线性方程组  $Ax = b$

回顾之前的记号:

$$A = D - L - U$$

$$D = \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{bmatrix} \quad L = \begin{bmatrix} 0 & & & \\ -a_{21} & 0 & & \\ \vdots & \ddots & \ddots & \\ -a_{n1} & \cdots & -a_{n,n-1} & 0 \end{bmatrix} \quad U = \begin{bmatrix} 0 & -a_{12} & \cdots & -a_{1n} \\ 0 & \ddots & \ddots & \vdots \\ \ddots & -a_{n-1,n} & & 0 \end{bmatrix}$$

$A$  的 Hermite 性保证了  $U = L^H$

于是  $B = (D - L)^{-1}U = (D - L)^{-1}L^H$

对于  $B$  的任意特征对  $(\lambda, x)$ , 我们都有:

$$\begin{aligned} Bx &= (D - L)^{-1}L^Hx = x\lambda \\ &\Updownarrow \\ L^Hx &= (D - L)x\lambda \end{aligned}$$

左乘  $x^H$  即得:

$$\begin{aligned} x^H L^H x &= x^H D x \lambda - x^H L x \lambda \\ &\Updownarrow \\ \bar{\beta} &= \alpha \lambda - \beta \lambda \text{ where } \begin{cases} \alpha = x^H D x \\ \beta = x^H L x \end{cases} \end{aligned}$$

因此我们有:

$$\begin{aligned} \lambda &= \frac{\bar{\beta}}{\alpha - \beta} \\ &= \frac{\operatorname{Re}(\beta) - i \cdot \operatorname{Im}(\beta)}{\alpha - \operatorname{Re}(\beta) - i \cdot \operatorname{Im}(\beta)} \end{aligned}$$

注意到  $A$  是 Hermite 正定阵, 因此对角阵  $D$  的对角元均为正实数.

于是我们有  $\alpha = x^H D x > 0$

此外我们有:

$$\begin{aligned} 0 &< x^H A x \\ &= x^H (D - L - L^H) x \\ &= x^H D x - x^H L x - x^H L^H x \\ &= \alpha - \beta - \bar{\beta} \\ &= \alpha - 2\operatorname{Re}(\beta) \end{aligned}$$

要证明  $|\lambda| < 1$ , 只需证明  $(\operatorname{Re}(\beta))^2 < (\alpha - \operatorname{Re}(\beta))^2 = \alpha^2 - 2\alpha\operatorname{Re}(\beta) + (\operatorname{Re}(\beta))^2$

即只需证明  $\alpha(\alpha - 2\operatorname{Re}(\beta)) > 0$

而这根据前面  $\alpha > 0$  和  $\alpha - 2\operatorname{Re}(\beta) > 0$  的结论可知是成立的.

因此 Gauss-Seidel 迭代格式的系数矩阵  $B = (D - L)^{-1}L^H$  的任意特征值  $\lambda$  都满足  $|\lambda| < 1$

这说明  $\rho(B) < 1$ , 因此 Gauss-Seidel 迭代法收敛.

从上述两个定理可以看到, 对 Jacobi 迭代法和 Gauss-Seidel 迭代法收敛性的判别,  
已经从对迭代矩阵  $B$  性质的研究转到对系数矩阵  $A$  性质的研究上来了, 这是一个很大的进展.  
然而矩阵正定性的判别并不很直观, 所以要把对判别条件的研究再深入一步.  
为此我们引进两个定义:

- (严格对角占优性)

设  $A = [a_{ij}] \in \mathbb{R}^{n \times n}$

若对任意  $1 \leq i \leq n$ , 都有  $|a_{ii}| \geq \sum_{j \neq i}^n |a_{ij}|$ , 且至少对一个  $i$  有严格不等号成立, 则称  $A$  是弱严格对角占优的.

若对任意  $1 \leq i \leq n$ , 都有  $|a_{ii}| > \sum_{j \neq i}^n |a_{ij}|$ , 则称  $A$  是严格对角占优的.

- (不可约性)

设  $A = [a_{ij}] \in \mathbb{R}^{n \times n}$

若存在排列方阵  $P \in \mathbb{R}^{n \times n}$  使得  $\begin{cases} PAP^T = \begin{bmatrix} A_{11} & \\ A_{12} & A_{22} \end{bmatrix} \\ A_{11} \in \mathbb{R}^{r \times r} \\ A_{22} \in \mathbb{R}^{(n-r) \times (n-r)} \end{cases}$ , 则称  $A$  是可约的.

否则称  $A$  是不可约的.

若  $A$  可约, 则可将  $Ax = b$  化为  $PAP^T Px = Pb$

记  $\begin{cases} Px = y \\ Pb = c \end{cases}$ , 即有:

$$(PAP^T)Px = \begin{bmatrix} A_{11} & \\ A_{12} & A_{22} \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} c_1 \\ c_2 \end{bmatrix} = Pb$$

利用前代法的思想, 我们可以先求解  $r$  阶方程组  $A_{11}y_1 = c_1$  得到  $y_1$

再代入  $A_{12}y_1 + A_{22}y_2 = c_2$  解得  $y_2$ .

这样就将求解一个高阶方程组的问题转化为求解两个低阶方程组.

**等价定义:**

设  $A = [a_{ij}] \in \mathbb{R}^{n \times n}$

若存在  $\{1, \dots, n\}$  的两个非空子集  $S_1, S_2$  使得  $\begin{cases} S_1 \cup S_2 = \{1, \dots, n\} \\ S_1 \cap S_2 = \emptyset \\ a_{ij} = 0 \ (\forall i \in S_1, j \in S_2) \end{cases}$

则称  $A$  是可约的; 否则称  $A$  不可约.

- 设  $A = [a_{ij}] \in \mathbb{R}^{n \times n}$

若  $A$  不可约, 且是弱严格对角占优的, 则称  $A$  不可约对角占优.

例如三对角阵  $T = \begin{bmatrix} 2 & -1 & & \\ -1 & 2 & -1 & \\ & -1 & 2 & -1 \\ & & -1 & 2 \end{bmatrix}$  就是不可约对角占优的.

(数值线性代数, 定理 4.2.8)

设  $A = [a_{ij}] \in \mathbb{R}^{n \times n}$

若矩阵  $A$  严格对角占优, 或不可约对角占优, 则  $A$  非奇异.

- 证明:

设  $A$  严格对角占优.

(反证法) 假设  $A$  非奇异, 则  $Ax = 0_n$  有非零解  $x$ .

不妨设  $|x_i| = \|x\|_\infty = 1$  (即  $x$  分量的最大模长是 1, 对应下标为  $i$ ), 则有:

$$\begin{aligned} |a_{ii}| &= |a_{ii}x_i| \\ &= |0 - \sum_{j \neq i}^n a_{ij}x_j| \\ &= |\sum_{j \neq i}^n a_{ij}x_j| \\ &\leq \sum_{j \neq i}^n |a_{ij}| |x_j| \\ &\leq \sum_{j \neq i}^n |a_{ij}| \cdot 1 \\ &= \sum_{j \neq i}^n |a_{ij}| \end{aligned}$$

这与严格对角占优性  $|a_{ii}| > \sum_{j \neq i}^n |a_{ij}| (i = 1, \dots, n)$  矛盾, 因而  $A$  非奇异.

设  $A$  不可约对角占优.

(反证法) 假设  $A$  非奇异, 则  $Ax = 0_n$  有非零解  $x$  (不妨设满足  $\|x\|_\infty = 1$ , 即分量最大模长为 1).

定义  $\begin{cases} S_1 := \{i : |x_i| = 1\} \\ S_2 := \{1, \dots, n\} \setminus S_1 = \{i : |x_i| < 1\} \end{cases}$  (显然满足  $\begin{cases} S_1 \cup S_2 = \{1, \dots, n\} \\ S_1 \cap S_2 = \emptyset \end{cases}$ )

- 显然  $S_1$  不是空集.

而  $S_2$  也不是空集, 这是因为:

假设  $S_2$  为空集, 即  $x$  的所有分量的模长都为 1.

则对于任意  $i = 1, \dots, n$ , 都有:

$$\begin{aligned} |a_{ii}| &= |a_{ii}x_i| \\ &= |0 - \sum_{j \neq i}^n a_{ij}x_j| \\ &= \left| \sum_{j \neq i}^n a_{ij}x_j \right| \\ &\leq \sum_{j \neq i}^n |a_{ij}| |x_j| \\ &= \sum_{j \neq i}^n |a_{ij}| \cdot 1 \\ &= \sum_{j \neq i}^n |a_{ij}| \end{aligned}$$

即没有一个  $i$  使得  $|a_{ii}| \geq \sum_{j \neq i}^n |a_{ij}|$  严格成立, 这与  $A$  弱严格对角占优矛盾, 因而  $S_2$  不是空集.

由于  $A$  不可约, 故必定存在  $\begin{cases} i \in S_1 \\ k \in S_2 \end{cases}$  使得  $a_{ik} \neq 0$ , 于是有:

(注意到  $|x_i| = 1$  和  $|x_k| < 1$ )

$$\begin{aligned} |a_{ii}| &= |a_{ii}x_i| \\ &= |0 - \sum_{j \neq i}^n a_{ij}x_j| \\ &= \left| \sum_{j \neq i}^n a_{ij}x_j \right| \\ &\leq \left| \sum_{j \in S_1 \setminus \{i\}} a_{ij}x_j \right| + \left| \sum_{j \in S_2 \setminus \{k\}} a_{ij}x_j \right| + |a_{ik}x_k| \\ &\leq \sum_{j \in S_1 \setminus \{i\}} |a_{ij}| |x_j| + \sum_{j \in S_2 \setminus \{k\}} |a_{ij}| |x_j| + |a_{ik}| |x_k| \\ &< \sum_{j \in S_1 \setminus \{i\}} |a_{ij}| \cdot 1 + \sum_{j \in S_2 \setminus \{k\}} |a_{ij}| \cdot 1 + |a_{ik}| \cdot 1 \quad (\text{note that the strict inequality stems from } \begin{cases} |a_{ik}| > 0 \\ |x_k| < 1 \end{cases}) \\ &= \sum_{j \neq i}^n |a_{ij}| \end{aligned}$$

这与  $A$  弱严格对角占优矛盾, 因而  $A$  非奇异.

#### (数值线性代数, 推论 4.2.1)

设  $A = [a_{ij}] \in \mathbb{R}^{n \times n}$  是对称阵 (即  $A^T = A$ ), 且对角元均为正数.

若  $A$  严格对角占优或不可约对角占优, 则  $A$  正定.

- **证明:** 对于任意  $\lambda \leq 0$ , 考虑矩阵  $A - \lambda I$

显然  $A - \lambda I$  也是严格对角占优或不可约对角占优的, 因此  $A - \lambda I$  总是非奇异的.

表明  $A$  的特征值均大于 0, 即  $A$  正定.

- "对角元均为正数" 的条件是有必要的,

因为严格对角占优或不可约对角占优只能保证对角元均非零, 即  $|a_{ii}| > 0$  ( $i = 1, \dots, n$ )

考虑非奇异线性方程组  $Ax = b$

回顾之前的记号:

$$A = D - L - U$$

$$D = \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{bmatrix} \quad L = \begin{bmatrix} 0 & & & \\ -a_{21} & 0 & & \\ \vdots & \ddots & \ddots & \\ -a_{n1} & \cdots & -a_{n,n-1} & 0 \end{bmatrix} \quad U = \begin{bmatrix} 0 & -a_{12} & \cdots & -a_{1n} \\ 0 & \ddots & & \vdots \\ \ddots & & -a_{n-1,n} \\ 0 & & & 0 \end{bmatrix}$$

### (数值线性代数, 定理 4.2.9)

若  $A$  严格对角占优或不可约对角占优, 则 Jacobi 迭代法和 Gauss-Seidel 迭代法都收敛.

- **(应用数值线性代数, 定理 6.2)**

若  $A$  严格对角占优, 则  $\|B_{G-S}\|_\infty \leq \|B_{Jacobi}\|_\infty < 1$

表明此时 Jacobi 迭代法和 Gauss-Seidel 迭代法都收敛,

且对于最差问题来说, Gauss-Seidel 单步迭代的效果至少不比 Jacobi 单步迭代的效果差.

(对于  $A$  严格列对角占优, 即  $A^T$  严格对角占优的情况, 我们有类似的结论)

- **(应用数值线性代数, 定理 6.3)**

若  $A$  不可约对角占优, 则  $\rho(B_{G-S}) \leq \rho(B_{Jacobi}) < 1$

表明此时 Jacobi 迭代法和 Gauss-Seidel 迭代法都收敛,

且 Gauss-Seidel 单步迭代的效果要比 Jacobi 单步迭代的效果更好.

- 尽管上述结果表明在一定条件下 Gauss-Seidel 迭代法要优于 Jacobi 迭代法,  
但此结论对于一般的情况并不一定成立.

**证明:**

" $A$  严格对角占优或不可约对角占优" 的条件保证了  $A$  的对角元均非零,

因而  $D$  和  $D - L$  都是可逆矩阵.

- 首先考虑 Jacobi 迭代法, 记  $\begin{cases} B = D^{-1}(L + U) \\ c = D^{-1}b \end{cases}$

**(反证法)** 假设 Jacobi 迭代法发散, 即  $\rho(B) \geq 1$ , 即存在  $B$  的某个特征值  $\lambda$  满足  $|\lambda| \geq 1$

于是  $A + (\lambda - 1)D = \lambda D - L - U$  也是严格对角占优或不可约对角占优的,

因此  $\lambda D - L - U$  非奇异.

由  $\lambda I - B = \lambda I - D^{-1}(L + U) = D^{-1}(\lambda D - L - U)$  可知  $\lambda I - B$  也是非奇异的.

这与 " $\lambda$  是  $B$  的特征值" 矛盾, 因而 Jacobi 迭代法收敛.

- 其次考虑 Gauss-Seidel 迭代法, 记  $\begin{cases} B = (D - L)^{-1}U \\ c = (D - L)^{-1}b \end{cases}$

**(反证法)** 假设 Gauss-Seidel 迭代法发散, 即  $\rho(B) \geq 1$ , 即存在  $B$  的某个特征值  $\lambda$  满足  $|\lambda| \geq 1$

于是  $A + (\lambda - 1)(D - L) = \lambda D - \lambda L - U$  也是严格对角占优或不可约对角占优的,

因此  $\lambda D - \lambda L - U$  非奇异.

由  $\lambda I - B = \lambda I - (D - L)^{-1}U = (D - L)^{-1}(\lambda D - \lambda L - U)$  可知  $\lambda I - B$  也是非奇异的.

这与 " $\lambda$  是  $B$  的特征值" 矛盾, 因而 Gauss-Seidel 迭代法收敛.

命题得证.

## 3.3 收敛速度

现在给出单步线性定常迭代法收敛速度的定量刻画.

### 3.3.1 基本定义

设  $x^*$  是非奇异线性方程组  $Ax = b$  的精确解.

考虑与  $Ax = b$  相容的单步线性定常迭代法  $x^{(k)} = Bx^{(k-1)} + c$  产生的迭代序列  $\{x^{(k)}\}$

若该迭代法收敛, 则其极限  $x^*$  满足  $x^* = Bx^* + c$

定义  $x^{(k)}$  误差向量为  $e^{(k)} = x^{(k)} - x^*$

$$\text{联立 } \begin{cases} x^{(k)} = Bx^{(k-1)} + c \\ x^* = Bx^* + c \\ e^{(k)} = x^{(k)} - x^* \\ e^{(k-1)} = x^{(k-1)} - x^* \end{cases} \text{ 可得 } e^{(k)} = B \cdot e^{(k-1)} \quad (k = 1, 2, \dots)$$

于是我们有  $e^{(k)} = B^k e^{(0)} \quad (k = 1, 2, \dots)$

因此  $\|e^{(k)}\| \leq \|B^k\| \|e^{(0)}\| \quad (k = 1, 2, \dots)$

初始误差  $\|e^{(0)}\|$  通常是未知的, 因此通常用  $\|B^k\|$  来刻画收敛速度.

我们定义  $k$  次迭代的平均收敛速度  $R_k := R_k(B) = -\frac{1}{k} \log (\|B^k\|)$

- 注意, 若迭代法收敛, 则  $\lim_{k \rightarrow \infty} \|B^k\| \rightarrow 0$

因此当  $k$  充分大时, 总有  $R_k > 0$

我们记  $\mu = \left( \frac{\|e^{(k)}\|}{\|e^{(0)}\|} \right) \approx \|B^k\|^{\frac{1}{k}} = e^{-R_k}$  为误差范数在  $k$  次迭代中的平均缩减因子.

- 一般情况下,  $R_k(B)$  既依赖于  $k$  又依赖于  $B$ , 因此计算起来很复杂.

但如果  $B$  是对称矩阵 (或 Hermite 阵, 或正规矩阵), 则有  $\|B^k\|_2 = (\rho(B))^k$

因此  $R_k(B) = -\frac{1}{k} \log(\|B^k\|_2) = -\frac{1}{k} \cdot k \log(\rho(B)) = -\log(\rho(B))$   
此时  $R_k(B)$  仅依赖于  $B$ , 不依赖于  $k$ .

设有两个迭代法, 对应的迭代矩阵分别为  $B^{(1)}$  和  $B^{(2)}$ .

若  $R_k(B^{(1)}) > R_k(B^{(2)}) > 0$ ,

则我们称前  $k$  次迭代中  $B^{(1)}$  对应的迭代法比  $B^{(2)}$  对应的迭代法收敛速度慢.

但可能对于某些  $k$  有  $R_k(B^{(1)}) > R_k(B^{(2)})$ , 而对另一些  $k$  有  $R_k(B^{(1)}) < R_k(B^{(2)})$

因此为了刻画整个迭代过程的收敛速度,

我们自然考虑定义渐近收敛速度  $R_\infty(B) := \lim_{k \rightarrow \infty} R_k(B) = -\lim_{k \rightarrow \infty} \frac{1}{k} \log(\|B^k\|) = -\lim_{k \rightarrow \infty} \log(\|B^k\|^{\frac{1}{k}})$

#### (数值线性代数, 定理 4.3.1)

给定  $\begin{cases} A \in \mathbb{R}^{n \times n} \\ b \in \mathbb{R}^n \end{cases}$  (设  $A$  非奇异)

考虑与  $Ax = b$  相容的单步线性定常迭代法  $x^{(k)} = Bx^{(k-1)} + c$

我们有  $R_\infty(B) = -\log(\rho(B))$  成立.

- 证明: 只需证明  $\lim_{k \rightarrow \infty} \|B^k\|^{\frac{1}{k}} = \rho(B)$  即可.

一方面, 因为  $(\rho(B))^k = \rho(B^k) \leq \|B^k\|$  ( $k = 1, 2, \dots$ ), 所以  $\rho(B) \leq \|B^k\|^{\frac{1}{k}}$  ( $k = 1, 2, \dots$ )

另一方面, 对于任意  $\varepsilon > 0$ , 考虑矩阵  $B_\varepsilon = \frac{1}{\rho(B)+\varepsilon} B$

显然有  $\rho(B_\varepsilon) < 1$ , 于是有  $\lim_{k \rightarrow \infty} B_\varepsilon^k = O_{n \times n}$  成立

因此存在正整数  $K$  使得对于任意  $k \geq K$  都有  $\|B_\varepsilon^k\| \leq 1$  成立,

即有  $\|B^k\| \leq (\rho(B) + \varepsilon)^k$  成立, 即有  $\|B^k\|^{\frac{1}{k}} \leq \rho(B) + \varepsilon$  成立.

综上所述, 对于任意  $\varepsilon > 0$  和足够大的  $k$  都有  $\rho(B) \leq \|B^k\|^{\frac{1}{k}} \leq \rho(B) + \varepsilon$  成立.

因此  $\lim_{k \rightarrow \infty} \|B^k\|^{\frac{1}{k}} = \rho(B)$ , 命题得证.

### 3.3.2 二维 Poisson 方程的求解

二维 Poisson 方程离散化得到的方程:

$$\begin{aligned}
 h &= \frac{1}{n+1} \\
 4u_{ij} - u_{i-1,j} - u_{i+1,j} - u_{i,j-1} - u_{i,j+1} &= h^2 f_{ij} \quad (1 \leq i, j \leq n) \\
 &\Downarrow \\
 T_n U + U T_n &= h^2 F \\
 T_n = \begin{bmatrix} 2 & -1 & & & \\ -1 & \ddots & \ddots & & \\ & \ddots & \ddots & -1 & \\ & & -1 & 2 & \end{bmatrix} & U = \begin{bmatrix} u_{1,1} & u_{1,2} & \cdots & u_{1,n} \\ u_{2,1} & u_{2,2} & \cdots & u_{2,n} \\ \vdots & \vdots & & \vdots \\ u_{n,1} & u_{n,2} & \cdots & u_{n,n} \end{bmatrix} & F = \begin{bmatrix} f_{1,1} & f_{1,2} & \cdots & f_{1,n} \\ f_{2,1} & f_{2,2} & \cdots & f_{2,n} \\ \vdots & \vdots & & \vdots \\ f_{n,1} & f_{n,2} & \cdots & f_{n,n} \end{bmatrix} \\
 &\Downarrow \\
 T_{n \times n} \text{vec}(U) &= h^2 \text{vec}(F) \\
 \text{where } T_{n \times n} := (I_n \otimes T_n + T_n \otimes I_n) &= \begin{bmatrix} T_n & & & \\ & \ddots & & \\ & & \ddots & \\ & & & T_n \end{bmatrix} + \begin{bmatrix} 2I_n & -I_n & & \\ -I_n & \ddots & \ddots & \\ & \ddots & \ddots & -I_n \\ & & -I_n & 2I_n \end{bmatrix}
 \end{aligned}$$

记  $A := T_{n \times n} = D - L - U$  (注意其中  $D = 4I$ )

Jacobi 迭代法计算模型问题的迭代矩阵和常数项为:

$$\begin{cases} B = D^{-1}(L + U) = D^{-1}(D - A) = I - D^{-1}A = I - (\frac{1}{4}I)A = I - \frac{1}{4}A \\ c = D^{-1}b = (\frac{1}{4}I)h^2 f = \frac{h^2}{4}f \end{cases}$$

考虑  $I - \frac{1}{4}A$  的结构:

$$I_{n^2} - \frac{1}{4}A = \frac{1}{4} \begin{bmatrix} 2I_n - T_n & I_n \\ I_n & \ddots & \ddots \\ \ddots & \ddots & I_n \\ I_n & 2I_n - T_n \end{bmatrix}$$

where  $T_n = \begin{bmatrix} 2 & -1 & & \\ -1 & \ddots & \ddots & \\ & \ddots & \ddots & -1 \\ & & -1 & 2 \end{bmatrix}$

$$2I_n - T_n = \begin{bmatrix} 0 & 1 & & \\ 1 & \ddots & \ddots & \\ & \ddots & \ddots & 1 \\ & & 1 & 0 \end{bmatrix}$$

于是其迭代格式  $u^{(k)} = Bu^{(k-1)} + c$  可表示为:

$$\begin{aligned} u^{(k)} &= Bu^{(k-1)} + c = (I - \frac{1}{4}A)u^{(k-1)} + \frac{h^2}{4}f \\ &\Updownarrow \\ u_{ij}^{(k)} &= \frac{1}{4}(u_{i-1,j}^{(k-1)} + u_{i,j-1}^{(k-1)} + u_{i+1,j}^{(k-1)} + u_{i,j+1}^{(k-1)}) + \frac{h^2}{4}f_{ij} \quad (i, j = 1, \dots, n) \end{aligned}$$

其中边界值  $u_{i,0} = u_{i,n+1} = u_{0,j} = u_{n+1,j} = 0$  ( $i, j = 1, \dots, n$ ) 在迭代过程中不改变.

总之, 我们有迭代公式:

$$\begin{cases} u_{ij}^{(k)} = \frac{1}{4}(u_{i-1,j}^{(k-1)} + u_{i,j-1}^{(k-1)} + u_{i+1,j}^{(k-1)} + u_{i,j+1}^{(k-1)}) + \frac{h^2}{4}f_{ij} & (i, j = 1, \dots, n) \\ u_{i,0}^{(k)} = u_{i,n+1}^{(k)} = u_{0,j}^{(k)} = u_{n+1,j}^{(k)} = 0 \end{cases}$$

迭代矩阵  $B = I - \frac{1}{4}A$  的特征值为:

$$\begin{aligned} \lambda_{p,q}(B) &= 1 - \frac{1}{4}\lambda_{p,q}(A) \\ &= 1 - \frac{1}{4} \cdot 2 \left( 2 - \cos\left(\frac{p\pi}{n+1}\right) - \cos\left(\frac{q\pi}{n+1}\right) \right) \\ &= \frac{1}{2} \left( \cos\left(\frac{p\pi}{n+1}\right) + \cos\left(\frac{q\pi}{n+1}\right) \right) \end{aligned}$$

因此谱半径为:

$$\begin{aligned} \rho(B) &= \max_{1 \leq p, q \leq n} |\lambda_{p,q}(B)| \\ &= \max_{1 \leq p, q \leq n} \left| \frac{1}{2} \left( \cos\left(\frac{p\pi}{n+1}\right) + \cos\left(\frac{q\pi}{n+1}\right) \right) \right| \\ &= \frac{1}{2} \left\{ \max_{1 \leq p \leq n} \left| \cos\left(\frac{p\pi}{n+1}\right) \right| + \max_{1 \leq q \leq n} \left| \cos\left(\frac{q\pi}{n+1}\right) \right| \right\} \\ &= \frac{1}{2} \left( \cos\left(\frac{\pi}{n+1}\right) + \cos\left(\frac{\pi}{n+1}\right) \right) \\ &= \cos\left(\frac{\pi}{n+1}\right) \\ &= \cos(h\pi) \quad (\text{note that } h = \frac{1}{n+1}) \end{aligned}$$

因此 Jacobi 迭代法求解模型问题的渐近收敛速度为:

$$\begin{aligned} R_\infty(B) &= -\log(\rho(B)) \\ &= -\log(\cos(h\pi)) \\ &= -\log\left(\sqrt{1 - (\sin(h\pi))^2}\right) \\ &= -\frac{1}{2}\log(1 - (\sin(h\pi))^2) \\ &\sim -\frac{1}{2} \cdot -(h\pi)^2 \\ &\sim -\frac{1}{2} \cdot -(h\pi)^2 \\ &= \frac{1}{2}\pi^2 h^2 \quad (h \rightarrow 0) \end{aligned}$$

Gauss-Seidel 迭代法的迭代格式为:

$$\begin{aligned} u^{(k)} &= (D - L)^{-1}Uu^{(k-1)} + (D - L)^{-1}b \\ &\Leftrightarrow \\ u^{(k)} &= D^{-1}Lu^{(k)} + D^{-1}Uu^{(k-1)} + D^{-1}b \end{aligned}$$

我们计算得:

$$\begin{aligned} D^{-1}L &= (\frac{1}{4}I)L = \frac{1}{4}L = \frac{1}{4} \begin{bmatrix} L_n & & & \\ I_n & \ddots & & \\ & \ddots & \ddots & \\ & & I_n & L_n \end{bmatrix} \quad \text{where } L_n = \begin{bmatrix} 0 & & & \\ 1 & \ddots & & \\ \ddots & \ddots & \ddots & \\ & & 1 & 0 \end{bmatrix} \\ D^{-1}U &= (\frac{1}{4}I)U = \frac{1}{4}U = \frac{1}{4} \begin{bmatrix} U_n & I_n & & \\ & \ddots & \ddots & \\ & & \ddots & I_n \\ & & & U_n \end{bmatrix} \quad \text{where } U_n = \begin{bmatrix} 0 & 1 & & \\ & \ddots & \ddots & \\ & & \ddots & 1 \\ & & & 0 \end{bmatrix} \\ D^{-1}b &= (\frac{1}{4}I)b = \frac{1}{4}b = \frac{h^2}{4}f \end{aligned}$$

因此  $u^{(k)} = D^{-1}Lu^{(k)} + D^{-1}Uu^{(k-1)} + D^{-1}b$  可表示为:

$$u_{ij}^{(k)} = \frac{1}{4}(u_{i-1,j}^{(k)} + u_{i,j-1}^{(k)} + u_{i+1,j}^{(k-1)} + u_{i,j+1}^{(k-1)}) + \frac{h^2}{4}f_{ij} \quad (i, j = 1, \dots, n)$$

于是迭代矩阵  $B^{(2)} = (D - L)^{-1}U$  的特征值  $\lambda$  满足:

$$\begin{cases} \lambda\xi_{i,j} = \frac{1}{4}(\lambda\xi_{i-1,j} + \lambda\xi_{i,j-1} + \xi_{i+1,j} + \xi_{i,j+1}) \\ \xi_{i,0} = \xi_{i,n+1} = \xi_{0,j} = \xi_{n+1,j} = 0 \end{cases}$$

设  $\lambda \neq 0$ , 作变换  $\xi_{i,j} = \lambda^{\frac{i+j}{2}}v_{i,j}$  可得:

$$\begin{aligned} \lambda\xi_{i,j} &= \lambda \cdot \lambda^{\frac{i+j}{2}}v_{i,j} \\ &= \lambda^{1+\frac{i+j}{2}}v_{i,j} \\ &= \frac{1}{4}(\lambda\xi_{i-1,j} + \lambda\xi_{i,j-1} + \xi_{i+1,j} + \xi_{i,j+1}) \\ &= \frac{1}{4}(\lambda \cdot \lambda^{\frac{i-1+j}{2}}v_{i-1,j} + \lambda \cdot \lambda^{\frac{i+j-1}{2}}v_{i,j-1} + \lambda^{\frac{i+1+j}{2}}v_{i+1,j} + \lambda^{\frac{i+j+1}{2}}v_{i,j+1}) \\ &= \frac{1}{4}\lambda^{\frac{i+j+1}{2}}(v_{i-1,j} + v_{i,j-1} + v_{i+1,j} + v_{i,j+1}) \end{aligned}$$

于是有:

$$\begin{aligned} \lambda^{1+\frac{i+j}{2}}v_{i,j} &= \frac{1}{4}\lambda^{\frac{i+j+1}{2}}(v_{i-1,j} + v_{i,j-1} + v_{i+1,j} + v_{i,j+1}) \\ &\Updownarrow \\ \lambda^{\frac{1}{2}}v_{i,j} &= \frac{1}{4}(v_{i-1,j} + v_{i,j-1} + v_{i+1,j} + v_{i,j+1}) \end{aligned}$$

回忆起 Jacobi 迭代法应用到二维 Poisson 问题得到的迭代公式:

$$\begin{cases} u_{ij}^{(k)} = \frac{1}{4}(u_{i-1,j}^{(k-1)} + u_{i,j-1}^{(k-1)} + u_{i+1,j}^{(k-1)} + u_{i,j+1}^{(k-1)}) + \frac{h^2}{4}f_{ij} \\ u_{i,0}^{(k)} = u_{i,n+1}^{(k)} = u_{0,j}^{(k)} = u_{n+1,j}^{(k)} = 0 \end{cases} \quad (i, j = 1, \dots, n)$$

我们知道迭代矩阵  $B^{(1)} = D^{-1}(L + U)$  的特征值  $\mu$  满足:

$$\begin{cases} \mu v_{i,j} = \frac{1}{4}(v_{i-1,j} + v_{i,j-1} + v_{i+1,j} + v_{i,j+1}) \\ v_{i,0} = v_{i,n+1} = v_{0,j} = v_{n+1,j} = 0 \end{cases} \quad (i, j = 1, \dots, n)$$

对比发现,  $\lambda \neq 0$  是 Gauss-Seidel 迭代矩阵  $B^{(2)} = (D - L)^{-1}U$  的非零特征值,  
当且仅当  $\mu = \lambda^{\frac{1}{2}}$  是 Jacobi 迭代矩阵  $B^{(1)} = D^{-1}(L + U)$  的非零特征值.

回忆起 Jacobi 迭代矩阵  $B^{(1)} = D^{-1}(L + U)$  的谱半径  $\rho(B^{(1)}) = \cos\left(\frac{\pi}{n+1}\right) = \cos(h\pi)$   
因此 Gauss-Seidel 迭代法求解模型问题的渐近收敛速度为:

$$\begin{aligned}
R_\infty(B^{(2)}) &= -\log(\rho(B^{(2)})) \\
&= -\log(\rho^2(B^{(1)})) \\
&= -2\log(\rho(B^{(1)})) \\
&= -2\log(\cos(h\pi)) \\
&\sim 2 \cdot \frac{1}{2}\pi^2 h^2 \\
&= \pi^2 h^2 \quad (h \rightarrow 0)
\end{aligned}$$

这说明 Gauss-Seidel 迭代法求解模型问题的渐近收敛速度是 Jacobi 迭代法的两倍.

## 3.4 超松弛迭代法

超松弛迭代法是 Gauss-Seidel 迭代法的引申和推广，也可看作 Gauss-Seidel 迭代法的加速.

### 3.4.1 迭代格式

考虑一个满足 "A 对角元均非零" 的非奇异线性方程组  $Ax = b$

回顾之前的记号:

$$A = D - L - U$$

$$D = \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{bmatrix} \quad L = \begin{bmatrix} 0 & & & \\ -a_{21} & 0 & & \\ \vdots & \ddots & \ddots & \\ -a_{n1} & \cdots & -a_{n,n-1} & 0 \end{bmatrix} \quad U = \begin{bmatrix} 0 & -a_{12} & \cdots & -a_{1n} \\ 0 & \ddots & \ddots & \vdots \\ \ddots & & -a_{n-1,n} & \\ 0 & & & \end{bmatrix}$$

Gauss-Seidel 迭代法的迭代格式为:

$$\begin{aligned}
x^{(k)} &= (D - L)^{-1}Ux^{(k-1)} + (D - L)^{-1}b \\
&\Downarrow \\
x^{(k)} &= D^{-1}Lx^{(k)} + D^{-1}Ux^{(k-1)} + D^{-1}b
\end{aligned}$$

现令修正项  $\Delta x^{(k-1)} = x^{(k)} - x^{(k-1)}$ , 则我们有:

$$\begin{aligned}
\Delta x^{(k-1)} &= x^{(k)} - x^{(k-1)} \\
&= (D^{-1}Lx^{(k)} + D^{-1}Ux^{(k-1)} + D^{-1}b) - x^{(k-1)}
\end{aligned}$$

若我们在修正项  $\Delta x^{(k-1)}$  的前面加上一个系数  $\omega > 0$ , 便得到松弛迭代法的迭代格式:

$$\begin{aligned}
x^{(k)} &= x^{(k-1)} + \omega\Delta x^{(k-1)} \\
&= x^{(k-1)} + \omega[(D^{-1}Lx^{(k)} + D^{-1}Ux^{(k-1)} + D^{-1}b) - x^{(k-1)}] \\
&= (1 - \omega)x^{(k-1)} + \omega(D^{-1}Lx^{(k)} + D^{-1}Ux^{(k-1)} + D^{-1}b)
\end{aligned}$$

我们称  $\omega$  为松弛因子:

- 当  $\omega > 1$  时, 称为超松弛迭代法 (简称为 SOR 迭代法)
- 当  $\omega = 1$  时, 就是 Gauss-Seidel 迭代法
- 当  $\omega < 1$  时, 称为低松弛迭代法

显然  $I - \omega D^{-1}L$  是下三角阵, 且对角元均非零 (前提条件是 A 对角元均非零), 因此它是可逆的.

于是我们可以改写松弛迭代法的迭代格式:

$$\begin{aligned}
x^{(k)} &= (1 - \omega)x^{(k-1)} + \omega(D^{-1}Lx^{(k)} + D^{-1}Ux^{(k-1)} + D^{-1}b) \\
&\Downarrow \\
x^{(k)} &= (I - \omega D^{-1}L)^{-1}[(D^{-1}U + (1 - \omega)I)x^{(k-1)} + \omega D^{-1}b] = (D - \omega L)^{-1}[(1 - \omega)D + \omega U]x^{(k-1)} + \omega(D - \omega L)^{-1}b \\
&\Downarrow \\
x^{(k)} &= B_\omega x^{(k-1)} + c_\omega \text{ where } \begin{cases} B_\omega = (D - \omega L)^{-1}[(1 - \omega)D + \omega U] \\ c_\omega = \omega(D - \omega L)^{-1}b \end{cases}
\end{aligned}$$

### 3.4.2 收敛性分析

现在我们研究超松弛迭代法的收敛性判别和松弛因子  $\omega$  的选取范围.

回顾之前的记号:

$$A = D - L - U$$

$$D = \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{bmatrix} \quad L = \begin{bmatrix} 0 & & & \\ -a_{21} & 0 & & \\ \vdots & \ddots & \ddots & \\ -a_{n1} & \cdots & -a_{n,n-1} & 0 \end{bmatrix} \quad U = \begin{bmatrix} 0 & -a_{12} & \cdots & -a_{1n} \\ 0 & \ddots & \ddots & \vdots \\ \ddots & & -a_{n-1,n} & \\ 0 & & & \end{bmatrix}$$

$$x^{(k)} = B_\omega x^{(k-1)} + c_\omega \text{ where } \begin{cases} B_\omega = (D - \omega L)^{-1}[(1 - \omega)D + \omega U] \\ c_\omega = \omega(D - \omega L)^{-1}b \end{cases}$$

(超松弛迭代法收敛的必要条件, 数值线性代数, 定理 4.4.2)

超松弛迭代法收敛的必要条件是  $0 < \omega < 2$

- 证明:

设超松弛迭代法收敛, 即等价于  $\rho(B_\omega) < 1$

设  $\lambda_1, \dots, \lambda_n$  是  $B_\omega$  的  $n$  个特征值, 则我们必须有:

$$\begin{aligned} |\det(B_\omega)| &= |\det\{(D - \omega L)^{-1}[(1 - \omega)D + \omega U]\}| \\ &= |\det\{(I - \omega D^{-1}L)^{-1}[(1 - \omega)I + \omega D^{-1}U]\}| \\ &= |\det\{(I - \omega D^{-1}L)^{-1}\}| |\det\{(1 - \omega)I + \omega D^{-1}U\}| \\ &= |1^n| \cdot |(1 - \omega)^n| \\ &= |(1 - \omega)^n| \\ &= |\lambda_1 \cdots \lambda_n| \\ &= |\lambda_1| \cdots |\lambda_n| \\ &< 1^n \\ &= 1 \end{aligned}$$

根据  $|(1 - \omega)^n| < 1$  可知  $|1 - \omega| < 1$ , 即有  $0 < \omega < 2$ , 命题得证.

(超松弛迭代法收敛的充分条件, 数值线性代数, 定理 4.4.3)

若系数矩阵  $A$  严格对角占优或不可约对角占优, 且松弛因子  $\omega \in (0, 1)$ , 则超松弛迭代法收敛.

- 证明:

" $A$  严格对角占优或不可约对角占优" 的条件保证了  $A$  的对角元均非零,

于是下三角阵  $D - \omega L$  的对角元也均非零, 因而是可逆的.

考虑超松弛迭代法  $\begin{cases} B_\omega = (D - \omega L)^{-1}[(1 - \omega)D + \omega U] \\ c_\omega = \omega(D - \omega L)^{-1}b \end{cases}$

(反证法) 假设超松弛迭代法发散, 即  $\rho(B_\omega) \geq 1$ , 即存在  $B_\omega$  的某个特征值  $\lambda$  满足  $|\lambda| \geq 1$

于是  $\omega A + (\lambda - 1)(D - \omega L) = (\omega + \lambda - 1)D - \omega \lambda L - \omega U$  也是严格对角占优或不可约对角占优的,  
因此  $(\omega + \lambda - 1)D - \omega \lambda L - \omega U$  非奇异.

由  $\lambda I - B_\omega = \lambda I - (D - \omega L)^{-1}[(1 - \omega)D + \omega U] = (D - \omega L)^{-1}[(\omega + \lambda - 1)D - \omega \lambda L - \omega U]$

可知  $\lambda I - B_\omega$  也是非奇异的.

这与 " $\lambda$  是  $B_\omega$  的特征值" 矛盾, 因而超松弛迭代法收敛.

(正定情形下超松弛迭代法收敛的充要条件, 数值线性代数, 定理 4.4.4)

若系数矩阵  $A$  对称正定, 则当且仅当松弛因子  $\omega \in (0, 2)$  时超松弛迭代法收敛.

- 证明:

由于系数矩阵  $A$  对称, 故  $U = L^T$

设  $\lambda$  是  $B_\omega$  的任一特征值(不一定是实数),  $x$  是对应的特征向量, 则有:

$$\begin{aligned} B_\omega x &= (D - \omega L)^{-1}[(1 - \omega)D + \omega U]x = \lambda x \\ &\Downarrow \\ [(1 - \omega)D + \omega L^T]x &= \lambda(D - \omega L)x \\ &\Downarrow \\ x^H[(1 - \omega)D + \omega L^T]x &= \lambda x^H(D - \omega L)x \end{aligned}$$

记  $\begin{cases} \gamma = x^H D x \\ \alpha + i\beta = x^H L x \Rightarrow x^H L^T x = \alpha - i\beta \end{cases}$  则我们有:

$$(1 - \omega)\gamma + \omega(\alpha - i\beta) = \lambda[\gamma - \omega(\alpha + i\beta)]$$

$$\Updownarrow$$

$$(1 - \omega)\gamma + \omega\alpha - i\omega\beta = \lambda(\gamma - \omega\alpha - i\omega\beta)$$

两边取模可得:

$$|\lambda|^2 = \frac{[(1 - \omega)\gamma + \omega\alpha]^2 + (\omega\beta)^2}{(\gamma - \omega\alpha)^2 + (\omega\beta)^2}$$

分子减分母可知:

$$\begin{aligned} & \{(1 - \omega)\gamma + \omega\alpha\}^2 + (\omega\beta)^2 - \{(\gamma - \omega\alpha)^2 + (\omega\beta)^2\} \\ &= [(1 - \omega)\gamma + \omega\alpha]^2 - (\gamma - \omega\alpha)^2 \\ &= [(1 - \omega)\gamma + \omega\alpha - (\gamma - \omega\alpha)] \cdot [(1 - \omega)\gamma + \omega\alpha + (\gamma - \omega\alpha)] \\ &= (2\omega\alpha - \omega\gamma)(2 - \omega)\gamma \\ &= \gamma(\gamma - 2\alpha)\omega(\omega - 2) \end{aligned}$$

由于  $A$  正定, 故我们有 (注意到  $x$  作为  $B_\omega$  的特征向量, 一定不是零向量):

$$\begin{cases} \delta = x^H D x > 0 \\ \delta - 2\alpha = \delta - (\alpha + i\beta) - (\alpha - i\beta) = x^H D x - x^H L x - x^H L^T x = x^H (D - L - U) x = x^H A x > 0 \end{cases}$$

因此  $|\lambda|^2 < 1$  (即  $|\lambda| < 1$ ) 当且仅当  $\omega(\omega - 2) < 0$ , 即  $\omega \in (0, 2)$

根据  $\lambda$  是  $B_\omega$  的任意特征值可知,  $\rho(B_\omega) < 1$  当且仅当  $\omega \in (0, 2)$

这表明超松弛迭代法收敛当且仅当  $\omega \in (0, 2)$ , 命题得证.

### 3.4.3 最佳松弛因子

要研究收敛速度在  $\omega$  为何值时最快, 我们考虑特征值问题:

$$\begin{aligned} B_\omega x &= (D - \omega L)^{-1}[(1 - \omega)D + \omega U]x = \lambda x \\ &\Updownarrow \\ &[(\lambda + \omega - 1)D - \lambda\omega L - \omega U]x = 0_n \end{aligned}$$

设  $\lambda_1, \dots, \lambda_n$  是  $B_\omega$  的  $n$  个特征值, 则我们有:

$$\begin{aligned} \det(B_\omega) &= \det\{(D - \omega L)^{-1}[(1 - \omega)D + \omega U]\} \\ &= \det\{(I - \omega D^{-1}L)^{-1}[(1 - \omega)I + \omega D^{-1}U]\} \\ &= \det\{(I - \omega D^{-1}L)^{-1}\} \det\{(1 - \omega)I + \omega D^{-1}U\} \\ &= 1^n \cdot (1 - \omega)^n \\ &= (1 - \omega)^n \end{aligned}$$

因此当  $\omega \neq 1$  时,  $B_\omega$  无零特征值.

二维 Poisson 方程离散化得到的方程:

$$\begin{aligned}
& h = \frac{1}{n+1} \\
& 4u_{ij} - u_{i-1,j} - u_{i+1,j} - u_{i,j-1} - u_{i,j+1} = h^2 f_{ij} \quad (1 \leq i, j \leq n) \\
& \Updownarrow \\
& T_n U + U T_n = h^2 F \\
& T_n = \begin{bmatrix} 2 & -1 & & \\ -1 & \ddots & \ddots & \\ & \ddots & \ddots & -1 \\ & & -1 & 2 \end{bmatrix} \quad U = \begin{bmatrix} u_{1,1} & u_{1,2} & \cdots & u_{1,n} \\ u_{2,1} & u_{2,2} & \cdots & u_{2,n} \\ \vdots & \vdots & & \vdots \\ u_{n,1} & u_{n,2} & \cdots & u_{n,n} \end{bmatrix} \quad F = \begin{bmatrix} f_{1,1} & f_{1,2} & \cdots & f_{1,n} \\ f_{2,1} & f_{2,2} & \cdots & f_{2,n} \\ \vdots & \vdots & & \vdots \\ f_{n,1} & f_{n,2} & \cdots & f_{n,n} \end{bmatrix} \\
& \Updownarrow \\
& T_{n \times n} \text{vec}(U) = h^2 \text{vec}(F) \\
& \text{where } T_{n \times n} := (I_n \otimes T_n + T_n \otimes I_n) = \begin{bmatrix} T_n & & & \\ & \ddots & & \\ & & \ddots & \\ & & & T_n \end{bmatrix} + \begin{bmatrix} 2I_n & -I_n & & \\ -I_n & \ddots & \ddots & \\ & \ddots & \ddots & -I_n \\ & & -I_n & 2I_n \end{bmatrix}
\end{aligned}$$

记  $A := T_{n \times n} = D - L - U$  (注意其中  $D = 4I$ )

在自然次序排列下,  $[(\lambda + \omega - 1)D - \lambda \omega L - \omega U]x = 0_n$  可写成:

$$\begin{cases} (\lambda + \omega - 1)u_{ij} - \frac{\omega}{4}(\lambda u_{i-1,j} + \lambda u_{i,j-1} + u_{i+1,j} + u_{i,j+1}) = 0 & (i, j = 1, \dots, n) \\ u_{i,0} = u_{i,n+1} = u_{0,j} = u_{n+1,j} = 0 \end{cases}$$

下面分两步讨论:

**第一步:** 找出 Jacobi 迭代矩阵  $B^{(1)} = D^{-1}(L + U)$  与  $B_\omega = (D - \omega L)^{-1}[(1 - \omega)D + \omega U]$  特征值之间的关系.

假设  $\omega \neq 1$  (这保证了  $B_\omega$  没有零特征值) (存疑:  $\lambda$  一定是正实数吗?)

对  $B_\omega$  的特征值  $\lambda$  作变换  $u_{i,j} = (\pm \lambda^{\frac{1}{2}})^{i+j} v_{i,j}$  可得:

$$\begin{aligned}
(\lambda + \omega - 1)u_{i,j} &= (\lambda + \omega - 1) \cdot (\pm \lambda^{\frac{1}{2}})^{i+j} v_{i,j} \\
&= \frac{\omega}{4}(\lambda u_{i-1,j} + \lambda u_{i,j-1} + u_{i+1,j} + u_{i,j+1}) \\
&= \frac{\omega}{4}[\lambda \cdot (\pm \lambda^{\frac{1}{2}})^{i-1+j} v_{i-1,j} + \lambda \cdot (\pm \lambda^{\frac{1}{2}})^{i+j-1} v_{i,j-1} + (\pm \lambda^{\frac{1}{2}})^{i+1+j} v_{i+1,j} + (\pm \lambda^{\frac{1}{2}})^{i+j+1} v_{i,j+1}] \\
&= \frac{\omega}{4}(\pm \lambda^{\frac{1}{2}})^{i+j+1}[v_{i-1,j} + v_{i,j-1} + v_{i+1,j} + v_{i,j+1}]
\end{aligned}$$

因此有:

$$\begin{cases} \mu v_{i,j} = \frac{1}{4}[v_{i-1,j} + v_{i,j-1} + v_{i+1,j} + v_{i,j+1}] & (i, j = 1, \dots, n) \\ v_{i,0} = v_{i,n+1} = v_{0,j} = v_{n+1,j} = 0 \end{cases} \quad \text{where } \mu = \pm \frac{\lambda + \omega - 1}{\omega \lambda^{\frac{1}{2}}}$$

回忆起 Jacobi 迭代法应用到二维 Poisson 问题得到的迭代公式:

$$\begin{cases} u_{ij}^{(k)} = \frac{1}{4}(u_{i-1,j}^{(k-1)} + u_{i,j-1}^{(k-1)} + u_{i+1,j}^{(k-1)} + u_{i,j+1}^{(k-1)}) + \frac{h^2}{4} f_{ij} & (i, j = 1, \dots, n) \\ u_{i,0}^{(k)} = u_{i,n+1}^{(k)} = u_{0,j}^{(k)} = u_{n+1,j}^{(k)} = 0 \end{cases}$$

我们知道迭代矩阵  $B^{(1)} = D^{-1}(L + U)$  的特征值  $\mu$  满足:

$$\begin{cases} \mu v_{i,j} = \frac{1}{4}(v_{i-1,j} + v_{i,j-1} + v_{i+1,j} + v_{i,j+1}) & (i, j = 1, \dots, n) \\ v_{i,0} = v_{i,n+1} = v_{0,j} = v_{n+1,j} = 0 \end{cases}$$

对比发现, 在  $\omega \neq 1$  的前提条件下,

$\lambda$  是松弛迭代矩阵  $B_\omega = (D - \omega L)^{-1}[(1 - \omega)D + \omega U]$  的特征值,

当且仅当  $\mu = \pm \frac{\lambda + \omega - 1}{\omega \lambda^{\frac{1}{2}}}$  是 Jacobi 迭代矩阵  $B^{(1)} = D^{-1}(L + U)$  的特征值.

- 实际上, 前面关于  $\omega \neq 1$  的限制是可以去掉的:

我们可以将  $\omega = 1$  的情况视作  $\omega \rightarrow 1$  的极限情况,

此时  $\mu = \pm \frac{\lambda + \omega - 1}{\omega \lambda^{\frac{1}{2}}}$  退化成  $\mu = \pm \lambda^{\frac{1}{2}}$

可知  $B^{(1)}$  的每对特征值  $\pm \mu_i$ , 都对应  $B_\omega = (D - \omega L)^{-1}[(1 - \omega)D + \omega U]$  的特征值 0 和  $\mu_i^2$

因此对于任意  $\omega \in (0, 2)$ , 我们都有:

$\lambda$  是松弛迭代矩阵  $B_\omega = (D - \omega L)^{-1}[(1 - \omega)D + \omega U]$  的特征值,  
当且仅当  $\mu = \pm \frac{\lambda + \omega - 1}{\omega \lambda^{\frac{1}{2}}}$  是 Jacobi 迭代矩阵  $B^{(1)} = D^{-1}(L + U)$  的特征值.

因此松弛迭代矩阵  $B_\omega$  的特征值完全由松弛因子  $\omega$  和 Jacobi 迭代矩阵  $B^{(1)}$  的特征值  $\mu$  确定.

## 第二步: 确定谱半径 $\rho(B_\omega)$ 随 $\omega$ 变化的情况

设  $0 \leq \mu < 1$  是 Jacobi 迭代矩阵  $B^{(1)}$  的一个特征值,  $\omega \in (0, 2)$

则由  $\mu = \pm \frac{\lambda + \omega - 1}{\omega \lambda^{\frac{1}{2}}}$  (即二次方程  $\lambda + \omega - 1 = \pm \mu \omega \lambda^{\frac{1}{2}}$ ) 可得松弛迭代矩阵  $B_\omega$  的两个特征值分别为:

$$\begin{aligned}\lambda_+(\omega, \mu) &= [\frac{\mu\omega}{2} + \sqrt{(\frac{\mu\omega}{2})^2 - (\omega - 1)}]^2 \\ \lambda_-(\omega, \mu) &= [\frac{\mu\omega}{2} - \sqrt{(\frac{\mu\omega}{2})^2 - (\omega - 1)}]^2\end{aligned}$$

记这两个特征值模长的最大值为  $M(\omega, \mu) := \max\{|\lambda_+(\omega, \mu)|, |\lambda_-(\omega, \mu)|\}$

记二次方程  $\lambda + \omega - 1 = \pm \mu \omega \lambda^{\frac{1}{2}}$  的判别式为  $\Delta = (\mu\omega)^2 - 4(\omega - 1)$

判别式  $\Delta$  在  $(0, 2)$  的唯一零点是  $\omega_\mu = \frac{2}{1 + \sqrt{1 - \mu^2}} \in (0, 2)$

- 当  $0 < \omega < \omega_\mu$  时  $\Delta > 0$ , 从而有  $\lambda_+(\omega, \mu) > \lambda_-(\omega, \mu) > 0$
- 当  $\omega = \omega_\mu$  时  $\Delta = 0$ , 从而有  $\lambda_+(\omega, \mu) = \lambda_-(\omega, \mu) > 0$
- 当  $\omega_\mu < \omega < 2$  时  $\Delta < 0$ , 故  $\lambda_+(\omega, \mu)$  和  $\lambda_-(\omega, \mu)$  为一对共轭复数, 且  $|\lambda_+(\omega, \mu)| = |\lambda_-(\omega, \mu)| = \omega - 1$

综上所述  $M(\omega, \mu) = \max\{|\lambda_+(\omega, \mu)|, |\lambda_-(\omega, \mu)|\} = \begin{cases} \lambda_+(\omega, \mu) & 0 < \omega \leq \omega_\mu \\ \omega - 1 & \omega_\mu < \omega < 2 \end{cases}$

固定  $0 \leq \mu < 1$ , 令  $\omega$  从 0 变到 2, 考虑  $M(\omega, \mu)$  的变化情况:

- 首先我们有  $M(\omega, \mu) < 1$ , 这是因为:

- 当  $0 < \omega \leq \omega_\mu$  时, 我们有:

$$\begin{aligned}M(\omega, \mu) &= \lambda_+(\omega, \mu) \\ &= [\frac{\mu\omega}{2} + \sqrt{(\frac{\mu\omega}{2})^2 - (\omega - 1)}]^2 \\ &\leq [\frac{\mu\omega}{2} + \sqrt{(\frac{\mu\omega}{2})^2 + 1 - 0}]^2 \\ &< [\frac{\mu\omega}{2} + \sqrt{(\frac{\mu\omega}{2})^2 + 1 - \mu\omega}]^2 \\ &= [\frac{\mu\omega}{2} + (1 - \frac{\mu\omega}{2})]^2 \\ &= 1\end{aligned}$$

- 当  $\omega_\mu < \omega < 2$  时, 我们有  $M(\omega, \mu) = \omega - 1 < 2 - 1 = 1$

- 其次, 当  $0 < \omega \leq \omega_\mu$  时, 我们有:

$$\begin{aligned}\frac{\partial M(\omega, \mu)}{\partial \omega} &= \frac{\partial}{\partial \omega} \left\{ [\frac{\mu\omega}{2} + \sqrt{(\frac{\mu\omega}{2})^2 - (\omega - 1)}]^2 \right\} \\ &= 2[\frac{\mu\omega}{2} + \sqrt{(\frac{\mu\omega}{2})^2 - (\omega - 1)}] \cdot [\frac{\mu}{2} + \frac{\frac{1}{2}\omega\mu^2 - 1}{2\sqrt{(\frac{\mu\omega}{2})^2 - (\omega - 1)}}] \\ &= M(\omega, \mu)^{\frac{1}{2}} \frac{\mu M(\omega, \mu)^{\frac{1}{2}} - 1}{\sqrt{(\frac{\mu\omega}{2})^2 - (\omega - 1)}} \\ &< 0\end{aligned}$$

于是当  $\omega \rightarrow \omega_\mu - 0$  时, 我们有 (注意到  $\omega_\mu$  是方程  $(\mu\omega)^2 - 4(\omega - 1) = 0$  的解):

$$\begin{aligned}M(\omega, \mu) &= [\frac{\mu\omega}{2} + \sqrt{(\frac{\mu\omega}{2})^2 - (\omega - 1)}]^2 \rightarrow (\frac{\mu\omega_\mu}{2})^2 = \omega_\mu - 1 = \frac{1 - \sqrt{1 - \mu^2}}{1 + \sqrt{1 - \mu^2}} \\ \frac{\partial M(\omega, \mu)}{\partial \omega} &= M(\omega, \mu)^{\frac{1}{2}} \frac{\mu M(\omega, \mu)^{\frac{1}{2}} - 1}{\sqrt{(\frac{\mu\omega}{2})^2 - (\omega - 1)}} \rightarrow \frac{\text{Negative Value}}{0} = -\infty\end{aligned}$$

而当  $\omega_\mu < \omega < 2$  时,  $M(\omega, \mu) = \omega - 1$  关于  $\omega$  严格单调递增.

综上所述, 对于固定的  $0 \leq \mu < 1$ ,

$M(\omega, \mu)$  关于  $\omega$  在  $(0, \omega_\mu)$  上严格单调递减, 在  $(\omega_\mu, 2)$  上严格单调递增, 因此在  $\omega_\mu$  处达到极小值  $\omega_\mu - 1 = \frac{1-\sqrt{1-\mu^2}}{1+\sqrt{1-\mu^2}}$

固定  $\omega \in (0, 2)$ , 考虑  $M(\omega, \mu)$  随  $0 \leq \mu < 1$  的变化情况:

可以证明, 若  $0 < \mu_1 < \mu_2 < 1$  是 Jacobi 迭代矩阵  $B^{(1)}$  的两个特征值, 则有  $M(\omega, \mu_1) \leq M(\omega, \mu_2)$  即  $M(\omega, \mu)$  关于  $\mu$  是单调递增的.

- 首先  $\omega_\mu = \frac{2}{1+\sqrt{1-\mu^2}} \in (0, 2)$  关于  $0 \leq \mu < 1$  严格单调递增, 因此  $\omega_{\mu_1} < \omega_{\mu_2}$
- 当  $\omega_{\mu_2} \leq \omega < 2$  时, 我们有  $\begin{cases} M(\omega, \mu_1) = \omega - 1 \\ M(\omega, \mu_2) = \omega - 1 \end{cases} \Rightarrow M(\omega, \mu_1) = M(\omega, \mu_2) = \omega - 1$
- 当  $0 < \omega \leq \omega_{\mu_1}$  时, 我们有  $\begin{cases} M(\omega, \mu_1) = [\frac{\mu_1 \omega}{2} + \sqrt{(\frac{\mu_1 \omega}{2})^2 - (\omega - 1)}]^2 \\ M(\omega, \mu_2) = [\frac{\mu_2 \omega}{2} + \sqrt{(\frac{\mu_2 \omega}{2})^2 - (\omega - 1)}]^2 \end{cases}$

$$\begin{aligned} M(\omega, \mu_2) - M(\omega, \mu_1) &= [M(\omega, \mu_2)^{\frac{1}{2}} + M(\omega, \mu_1)^{\frac{1}{2}}] \cdot [M(\omega, \mu_2)^{\frac{1}{2}} - M(\omega, \mu_1)^{\frac{1}{2}}] \\ &= [M(\omega, \mu_2)^{\frac{1}{2}} + M(\omega, \mu_1)^{\frac{1}{2}}] \cdot [\frac{\mu_2 \omega}{2} + \sqrt{(\frac{\mu_2 \omega}{2})^2 - (\omega - 1)} - \frac{\mu_1 \omega}{2} - \sqrt{(\frac{\mu_1 \omega}{2})^2 - (\omega - 1)}] \\ &= [M(\omega, \mu_2)^{\frac{1}{2}} + M(\omega, \mu_1)^{\frac{1}{2}}] \cdot [\frac{\omega(\mu_2 - \mu_1)}{2} + \frac{\frac{\omega^2}{4}(\mu_2^2 - \mu_1^2)}{\sqrt{(\frac{\mu_2 \omega}{2})^2 - (\omega - 1)} + \sqrt{(\frac{\mu_1 \omega}{2})^2 - (\omega - 1)}}] \\ &> 0 \end{aligned}$$

- 当  $\omega_{\mu_1} < \omega \leq \omega_{\mu_2}$  时, 我们有  $\begin{cases} M(\omega, \mu_1) = \omega - 1 \\ M(\omega, \mu_2) = [\frac{\mu_2 \omega}{2} + \sqrt{(\frac{\mu_2 \omega}{2})^2 - (\omega - 1)}]^2 \end{cases}$

$$\begin{aligned} M(\omega, \mu_2) &\geq \omega_{\mu_2} - 1 \quad (\text{Note that } \inf_{0 < \omega < 2} M(\omega, \mu_2) = \omega_{\mu_2} - 1) \\ &\geq \omega - 1 \\ &= M(\omega, \mu_1) \end{aligned}$$

综上所述, 对于固定的  $0 < \omega < 2$ ,  $M(\omega, \mu)$  关于  $0 \leq \mu < 1$  是单调递增的.

对于 Jacobi 迭代矩阵  $B^{(1)}$  的任意给定的特征值  $\mu$ , 我们都可绘制一条  $M(\omega, \mu)$  关于  $\omega$  的曲线.

它关于  $\omega$  在  $(0, \omega_\mu)$  上严格单调递减, 在  $(\omega_\mu, 2)$  上严格单调递增, 因此在  $\omega_\mu$  处达到极小值  $\omega_\mu - 1 = \frac{1-\sqrt{1-\mu^2}}{1+\sqrt{1-\mu^2}}$

而对于确定的  $\omega$ ,  $M(\omega, \mu)$  又是  $\mu$  的增函数,

因此 Jacobi 迭代矩阵  $B^{(1)}$  的较大特征值对应的曲线在较小特征值对应的曲线的上方.

于是 Jacobi 迭代矩阵  $B^{(1)}$  取到谱半径  $\rho(B^{(1)})$  的特征值  $\mu_{\max}$  对应的是最上方的曲线, 同时也对应着  $\rho(B_\omega)$  如图所示:

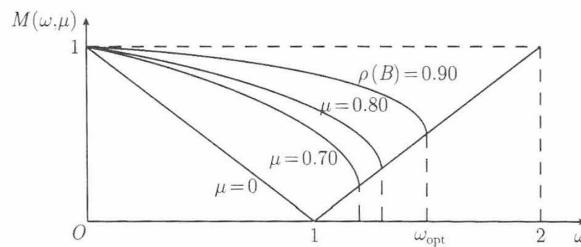


图 4.3

根据最上方的曲线  $\rho(B_\omega) = \max_{0 \leq \mu < 1} M(\omega, \mu) = M(\omega, \mu_{\max})$ , 我们得到结论:

- 当  $0 < \omega \leq \omega_{\max} = \frac{2}{1+\sqrt{1-(\rho(B^{(1)}))^2}}$  时  $\rho(B_\omega) = [\frac{\mu_{\max} \omega}{2} + \sqrt{(\frac{\mu_{\max} \omega}{2})^2 - (\omega - 1)}]^2$  严格单调递减
- 当  $\omega_{\max} < \omega < 2$  时  $\rho(B_\omega) = \omega - 1$  严格单调递增

因此  $\rho(B_\omega)$  在  $\omega_{\max}$  处取到极小值  $\omega_{\max} - 1 = \frac{1-\sqrt{1-(\rho(B^{(1)}))^2}}{1+\sqrt{1-(\rho(B^{(1)}))^2}}$

我们称  $\omega_{\max} = \frac{2}{1+\sqrt{1-(\rho(B^{(1)}))^2}}$  为最佳松弛因子

对应的最佳松弛迭代矩阵记为  $B_{\omega_{\max}} = (D - \omega_{\max} L)^{-1}[(1 - \omega_{\max})D + \omega_{\max} U]$   
(由于  $\omega_{\max} > 1$ , 故对应的松弛迭代是超松弛迭代)

在实际计算中，我们有时无法确定 Jacobi 迭代矩阵的谱半径  $\rho(B^{(1)})$ ，因此最佳松弛因子  $\omega_{\text{opt}}$  也无法确定。此时如何求近似的  $\omega_{\text{opt}}$  呢？

我们通常选取不同的松弛因子  $\omega \in (0, 2)$ ，

然后用相同的初始向量  $x^{(0)}$  进行试算，迭代相同次数（得到  $x^{(k_0)}$ ），比较残差向量的范数  $\|b - Ax^{(k_0)}\|$

最后选取使残差向量范数最小的  $\omega$  作为松弛因子。

另外，根据松弛迭代矩阵  $B_\omega$  的谱范数  $\rho(B_\omega)$  随  $\omega$  变化的曲线来看，

当我们不能得到准确的最佳松弛因子时，宁可取得稍大一些，因为  $\omega_{\text{opt}}$  左侧的曲线比右侧更加陡峭。

### 3.4.4 渐近收敛速度

最佳松弛因子  $\omega_{\text{opt}}$  对应的（超）松弛迭代法的渐近收敛速度为：

（回忆起 Jacobi 迭代矩阵的谱半径  $\rho(B^{(1)}) = \cos(\frac{\pi}{n+1}) = \cos(h\pi)$ ）

$$\begin{aligned} R_\infty(B_{\omega_{\text{opt}}}) &= -\log(\rho(B_{\omega_{\text{opt}}})) \\ &= -\log\left(\frac{1-\sqrt{1-(\rho(B^{(1)}))^2}}{1+\sqrt{1-(\rho(B^{(1)}))^2}}\right) \\ &= -\log\left(\frac{1-\sqrt{1-(\cos(h\pi))^2}}{1+\sqrt{1-(\cos(h\pi))^2}}\right) \\ &= -\log\left(\frac{1-\sin(h\pi)}{1+\sin(h\pi)}\right) \\ &= -\log(1-\sin(h\pi)) + \log(1+\sin(h\pi)) \\ &\sim -(-\sin(h\pi)) + \sin(h\pi) \\ &\sim -(-h\pi) + h\pi \\ &= 2h\pi \quad (h \rightarrow 0) \end{aligned}$$

回忆起  $\begin{cases} R_\infty(B^{(1)}) = R_\infty(D^{-1}(L+U)) = \frac{1}{2}\pi^2h^2 & (h \rightarrow 0) \\ R_\infty(B^{(2)}) = R_\infty((D-L)^{-1}U) = \pi^2h^2 \end{cases}$

可以看出，使用最佳松弛因子的超松弛迭代法的收敛速度比 Jacobi 迭代法和 Gauss-Seidel 迭代法快得多。

### 3.4.5 超松弛理论的推广

前面的讨论都基于二维 Poisson 问题，事实上我们可以将其推广到更一般的情形。

（数值线性代数，定理 4.4.5）

设线性方程组  $Ax = b$  的系数矩阵  $A$  具有块三对角形式：

$$A = \begin{bmatrix} D_1 & K_1 & & & \\ H_1 & D_2 & K_2 & & \\ & H_2 & D_3 & \ddots & \\ & \ddots & \ddots & \ddots & K_{m-1} \\ & & H_{m-1} & D_m & \end{bmatrix}$$

其中  $D_i$  ( $i = 1, \dots, m$ ) 是非奇异的对角阵。

我们记：

$$A = D - L - U$$

$$D = \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{bmatrix} \quad L = \begin{bmatrix} 0 & & & \\ -a_{21} & 0 & & \\ \vdots & \ddots & \ddots & \\ -a_{n1} & \cdots & -a_{n,n-1} & 0 \end{bmatrix} \quad U = \begin{bmatrix} 0 & -a_{12} & \cdots & -a_{1n} \\ 0 & \ddots & \ddots & \vdots \\ \ddots & \ddots & -a_{n-1,n} & \\ 0 & & & \end{bmatrix}$$

设  $\begin{cases} B^{(1)} = D^{-1}(L+U) \\ B^{(2)} = (D-L)^{-1}U \\ B_\omega = (D-\omega L)^{-1}[(1-\omega)D+\omega U] \end{cases}$  分别为 Jacobi 迭代法、Gauss-Seidel 迭代法和超松弛迭代法的迭代矩阵。

若  $B^{(1)}$  的特征值均为实数，则我们有：

- Jacobi 迭代矩阵和超松弛迭代矩阵的特征值之间的关系:

若  $\mu \neq 0$  是 Jacobi 迭代矩阵  $B^{(1)}$  的特征值,

则由  $\mu = \pm \frac{\lambda + \omega - 1}{\omega \lambda^{\frac{1}{2}}}$  (即二次方程  $\lambda + \omega - 1 = \pm \mu \omega \lambda^{\frac{1}{2}}$ ) 可得松弛迭代矩阵  $B_\omega$  的两个特征值分别为:

$$\lambda_+(\omega, \mu) = [\frac{\mu\omega}{2} + \sqrt{(\frac{\mu\omega}{2})^2 - (\omega - 1)^2}]^2$$

$$\lambda_-(\omega, \mu) = [\frac{\mu\omega}{2} - \sqrt{(\frac{\mu\omega}{2})^2 - (\omega - 1)^2}]^2$$

反过来, 若  $\lambda \neq 0$  是超松弛迭代矩阵  $B_\omega$  的特征值,

则  $\mu = \pm \frac{\lambda + \omega - 1}{\omega \lambda^{\frac{1}{2}}}$  是 Jacobi 迭代矩阵  $B^{(1)}$  的两个特征值.

(因此若  $\mu \neq 0$  是  $B^{(1)}$  的特征值, 则  $-\mu$  也是  $B^{(1)}$  的特征值)

**特殊地, 当  $\omega = 1$  时, 我们得到 Jacobi 迭代矩阵和 Gauss-Seidel 迭代矩阵的特征值之间的关系:**

$\lambda \neq 0$  是 Gauss-Seidel 迭代矩阵  $B^{(2)} = (D - L)^{-1}U$  的非零特征值,

当且仅当  $\mu = \lambda^{\frac{1}{2}}$  是 Jacobi 迭代矩阵  $B^{(1)} = D^{-1}(L + U)$  的非零特征值.

因此谱半径具有关系:  $\rho(B^{(2)}) = (\rho(B^{(1)}))^2$

渐近收敛速度  $R_\infty(B^{(2)}) = -\log(\rho(B^{(2)})) = -2\log(\rho(B^{(1)})) = 2R_\infty(B^{(1)})$

- 最佳松弛因子的相关陈述:

若 Jacobi 迭代矩阵的谱半径  $\rho(B^{(1)}) < 1$  且松弛因子  $0 < \omega < 2$ ,

则超松弛迭代法收敛, 且最佳松弛因子为  $\omega_{\text{opt}} = \frac{2}{1 + \sqrt{1 - (\rho(B^{(1)}))^2}}$

对应的谱半径  $\rho(B_{\omega_{\text{opt}}}) = \omega_{\text{opt}} - 1 = \frac{1 - \sqrt{1 - (\rho(B^{(1)}))^2}}{1 + \sqrt{1 - (\rho(B^{(1)}))^2}}$

当  $\rho(B^{(1)})$  从下方趋近于 1 时, 我们有渐近收敛速度  $R_\infty(B_{\omega_{\text{opt}}}) \sim 2\sqrt{2R_\infty(B^{(1)})}$

上述定理要求线性方程组的系数矩阵是块三对角阵, 且对角块为非奇异对角阵.

但是 "对角块为非奇异对角阵" 的要求太苛刻了.

回忆起二维 Poisson 问题中, 系数矩阵  $A$  的对角块为  $T_n + 2I_n$  是三对角阵, 而不是对角阵.

$$T_n + 2I_n = \begin{bmatrix} 4 & -1 & & & \\ -1 & \ddots & \ddots & & \\ & \ddots & \ddots & -1 & \\ & & -1 & 4 & \end{bmatrix}$$

然而我们成功对它建立了超松弛理论.

实际上, 超松弛理论可以适用于一类更广泛的矩阵.

为此, 我们引入相容性的概念.

### (具有相容次序的矩阵)

设  $A$  是  $n$  阶方阵.

我们称  $A$  是具有相容次序的矩阵,

如果存在  $\{1, \dots, n\}$  的一个划分  $S_1, \dots, S_m$  使得每个非零非对角元  $a_{ij} \neq 0$  ( $i \neq j$ ) 的下标  $i, j$  满足:

若  $i \in S_k$ , 则  $j \in \begin{cases} S_{k-1} & j < i \\ S_{k+1} & j > i \end{cases}$  (其中  $k = 1, \dots, m$ )

- 以二维 Poisson 问题的系数矩阵  $A = T_{n \times n}$  为例, 取  $n = 3$  的情况.

$$A = \left[ \begin{array}{ccc|ccc|c} 4 & -1 & & -1 & & & \\ -1 & 4 & -1 & & -1 & & \\ & -1 & 4 & & & -1 & \\ \hline -1 & & & 4 & -1 & & -1 \\ & -1 & & -1 & 4 & -1 & \\ & & -1 & & -1 & 4 & \\ \hline & & & -1 & & 4 & -1 \\ & & & & -1 & -1 & 4 \\ & & & & & -1 & -1 \end{array} \right]$$

我们取集合  $\{1, \dots, 9\}$  的划分为:

$$S_1 = \{1\} \quad S_2 = \{2, 4\} \quad S_3 = \{3, 5, 7\} \quad S_4 = \{6, 8\} \quad S_5 = \{9\}$$

可以验证这个划分是满足定义的，也就是说上述矩阵具有相容性次序。

对于具有相容性次序且对角元非零的矩阵，亦可建立超松弛理论。

这是因为它可以按照“相容性次序”定义中的  $\{1, \dots, n\}$  的划分  $S_1, \dots, S_m$

重排得到数值线性代数 定理 4.4.5 中描述的对角块均为非奇异对角阵的块三对角阵。

#### (数值线性代数, 定理 4.4.6)

设线性方程组  $Ax = b$  的系数矩阵  $A$  具有相容性次序，且对角元均不为零。

设  $\begin{cases} B^{(1)} = D^{-1}(L + U) \\ B^{(2)} = (D - L)^{-1}U \\ B_\omega = (D - \omega L)^{-1}[(1 - \omega)D + \omega U] \end{cases}$  分别为 Jacobi 迭代法、Gauss-Seidel 迭代法和超松弛迭代法的迭代矩阵。

若  $B^{(1)}$  的特征值均为实数，则我们有：

- **Jacobi 迭代矩阵和超松弛迭代矩阵的特征值之间的关系：**

若  $\mu \neq 0$  是 Jacobi 迭代矩阵  $B^{(1)}$  的特征值，

则由  $\mu = \pm \frac{\lambda + \omega - 1}{\omega \lambda^{\frac{1}{2}}}$  (即二次方程  $\lambda + \omega - 1 = \pm \mu \omega \lambda^{\frac{1}{2}}$ ) 可得松弛迭代矩阵  $B_\omega$  的两个特征值分别为：

$$\lambda_+(\omega, \mu) = \left[ \frac{\mu\omega}{2} + \sqrt{\left(\frac{\mu\omega}{2}\right)^2 - (\omega - 1)} \right]^2$$

$$\lambda_-(\omega, \mu) = \left[ \frac{\mu\omega}{2} - \sqrt{\left(\frac{\mu\omega}{2}\right)^2 - (\omega - 1)} \right]^2$$

反过来，若  $\lambda \neq 0$  是超松弛迭代矩阵  $B_\omega$  的特征值，

则  $\mu = \pm \frac{\lambda + \omega - 1}{\omega \lambda^{\frac{1}{2}}}$  是 Jacobi 迭代矩阵  $B^{(1)}$  的两个特征值。

(因此若  $\mu \neq 0$  是  $B^{(1)}$  的特征值，则  $-\mu$  也是  $B^{(1)}$  的特征值)

**特殊地，当  $\omega = 1$  时，我们得到 Jacobi 迭代矩阵和 Gauss-Seidel 迭代矩阵的特征值之间的关系：**

$\lambda \neq 0$  是 Gauss-Seidel 迭代矩阵  $B^{(2)} = (D - L)^{-1}U$  的非零特征值，

当且仅当  $\mu = \lambda^{\frac{1}{2}}$  是 Jacobi 迭代矩阵  $B^{(1)} = D^{-1}(L + U)$  的非零特征值。

因此谱半径具有关系:  $\rho(B^{(2)}) = (\rho(B^{(1)}))^2$

渐近收敛速度  $R_\infty(B^{(2)}) = -\log(\rho(B^{(2)})) = -2\log(\rho(B^{(1)})) = 2R_\infty(B^{(1)})$

- **最佳松弛因子的相关陈述：**

若 Jacobi 迭代矩阵的谱半径  $\rho(B^{(1)}) < 1$  且松弛因子  $0 < \omega < 2$ ，

则超松弛迭代法收敛，且最佳松弛因子为  $\omega_{\text{opt}} = \frac{2}{1 + \sqrt{1 - (\rho(B^{(1)}))^2}}$

对应的谱半径  $\rho(B_{\omega_{\text{opt}}}) = \omega_{\text{opt}} - 1 = \frac{1 - \sqrt{1 - (\rho(B^{(1)}))^2}}{1 + \sqrt{1 - (\rho(B^{(1)}))^2}}$

当  $\rho(B^{(1)})$  从下方趋近于 1 时，我们有渐近收敛速度  $R_\infty(B_{\omega_{\text{opt}}}) \sim 2\sqrt{2R_\infty(B^{(1)})}$

最后我们给出如下定理：

#### (数值线性代数, 定理 4.4.7)

若线性方程组  $Ax = b$  的系数矩阵  $A$  对称正定，且具有相容性次序，

则 Jacobi 迭代矩阵  $B^{(1)} = D^{-1}(L + U) = I - D^{-1}A$  的特征值均为实数，且谱半径  $\rho(B^{(1)}) < 1$

- 回顾之前的记号：

$$A = D - L - U$$

$$D = \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{bmatrix} \quad L = \begin{bmatrix} 0 & & & \\ -a_{21} & 0 & & \\ \vdots & \ddots & \ddots & \\ -a_{n1} & \cdots & -a_{n,n-1} & 0 \end{bmatrix} \quad U = \begin{bmatrix} 0 & -a_{12} & \cdots & -a_{1n} \\ 0 & \ddots & \ddots & \vdots \\ \ddots & \ddots & -a_{n-1,n} \\ 0 & & & 0 \end{bmatrix}$$

- **证明：**

因为  $A$  为正定阵，所以  $D = \text{diag}(a_{11}, \dots, a_{nn})$  为正定对角阵

于是  $B^{(1)} = I - D^{-1}A = D^{-\frac{1}{2}}(I - D^{-\frac{1}{2}}AD^{-\frac{1}{2}})D^{\frac{1}{2}}$

表明  $B^{(1)}$  与对称阵  $I - D^{-\frac{1}{2}}AD^{-\frac{1}{2}}$  相似，因而  $B^{(1)}$  的特征值均为实数。

#### (数值线性代数, 定理 4.2.7)

若  $A$  对称正定，则 Gauss-Seidel 迭代法收敛。

我们知道 Gauss-Seidel 迭代法收敛

因此 Gauss-Seidel 迭代矩阵  $B^{(2)} = (D - L)^{-1}U$  的谱半径  $\rho(B^{(2)}) < 1$

而根据**数值线性代数 定理 4.4.6** 的结论，我们有  $\rho(B^{(1)}) = \sqrt{\rho(B^{(2)})} < 1$

表明 Jacobi 迭代法也收敛，命题得证.

The End