

Problem 1 (20 Points)

In this True or False problem, no explanation is required for your answer.

If you answer correctly, you will earn 2 points.

However, if your answer is incorrect, you will lose 1 point.

If you choose not to answer at all, you will receive no points.

1. $f(x) = (\sum_{i=1}^n x_i^{\frac{1}{2}})^2$ is convex on \mathbb{R}_{++}^n .

o **False**

o **反例:**

考虑 $n = 2$ 的情况, $f(x) = x_1 + x_2 + \sqrt{x_1 x_2}$

取 $\begin{cases} x_1 = (1, 9) \\ x_2 = (9, 1) \end{cases}$, 考虑其连线中点 $\frac{1}{2}x_1 + \frac{1}{2}x_2 = (5, 5)$:

$$\begin{aligned} f\left(\frac{1}{2}x_1 + \frac{1}{2}x_2\right) - \left[\frac{1}{2}f(x_1) + \frac{1}{2}f(x_2)\right] &= f(5, 5) - \frac{1}{2}f(1, 9) - \frac{1}{2}f(9, 1) \\ &= 15 - \frac{13}{2} - \frac{13}{2} \\ &= 2 > 0 \end{aligned}$$

显然不满足凸性 (凸性要求凸组合的函数值 \leq 函数值的凸组合)

o **证明:**

我们记 $x \in \mathbb{R}_{++}^n$ 的逐元素 a 次幂运算的结果为 x^a

$$\text{则 } f(x) = \left(\sum_{i=1}^n x_i^{\frac{1}{2}}\right)^2 = (1_n^T x^{\frac{1}{2}})^2 = (x^{\frac{1}{2}})^T (1_n 1_n^T) (x^{\frac{1}{2}})$$

对于任意 $x \in \mathbb{R}_{++}^n$ 计算梯度得:

$$\begin{aligned} \nabla_x f(x) &= \nabla_x \{x^{\frac{1}{2}}\} \cdot 2(1_n 1_n^T) x^{\frac{1}{2}} \\ &= \text{diag}\left(\frac{1}{2} x^{-\frac{1}{2}}\right) \cdot 2(1_n 1_n^T) x^{\frac{1}{2}} \\ &= x^{-\frac{1}{2}} 1_n^T x^{\frac{1}{2}} \\ &= (1_n^T x^{\frac{1}{2}}) x^{-\frac{1}{2}} \end{aligned}$$

对于任意 $x \in \mathbb{R}_{++}^n$ 计算 Hessian 矩阵得:

$$\begin{aligned} \nabla_{xx}^2 f(x) &= \nabla_x \{x^{\frac{1}{2}}\} \cdot 1_n (x^{-\frac{1}{2}})^T + (1_n^T x^{\frac{1}{2}}) \cdot \nabla_x \{x^{-\frac{1}{2}}\} \\ &= \text{diag}\left(\frac{1}{2} x^{-\frac{1}{2}}\right) \cdot 1_n (x^{-\frac{1}{2}})^T + (1_n^T x^{\frac{1}{2}}) \cdot \text{diag}\left(-\frac{1}{2} x^{-\frac{3}{2}}\right) \\ &= \frac{1}{2} x^{-\frac{1}{2}} (x^{-\frac{1}{2}})^T - \frac{1}{2} x^{\frac{1}{2}} (x^{-\frac{3}{2}})^T \end{aligned}$$

■ 对于 $n = 1$ 的情况, $f''(x) \equiv 0$, 此时 f 在 \mathbb{R}_{++}^n 上为仿射函数, 自然是凸的.

■ 对于 $n \geq 2$ 的情况, 我们注意到:

对于任意 $i = 1, \dots, n$, $\nabla_{xx}^2 f(x)$ 的第 i 个对角元为 $\frac{1}{2}(x_i^{-\frac{1}{2}} x_i^{-\frac{1}{2}} - x_i^{\frac{1}{2}} x_i^{-\frac{3}{2}}) = 0$
因此要使得 $\nabla_{xx}^2 f(x) \succeq 0$, 其所有非对角元都必须为 0.

对于任意 $i \neq j \in \{1, \dots, n\}$, $\nabla_{xx}^2 f(x)$ 在 (i, j) 位置的非对角元为:

$$\nabla_{xx}^2 f(x)_{(i,j)} = \frac{1}{2}(x_i^{-\frac{1}{2}} x_j^{-\frac{1}{2}} - x_i^{\frac{1}{2}} x_j^{-\frac{3}{2}})$$

显然并不是所有的 $x \in \mathbb{R}_+^n$ 都能保证 $\nabla_{xx}^2 f(x)$ 的非对角元均为 0,

因而不能保证 $\nabla_{xx}^2 f(x)$ 半正定,

所以在 $n \geq 2$ 的情况下 f 并不是 \mathbb{R}_{++}^n 上的凸函数.

2. Consider the constrained optimization problem:

$$\min f(x)$$

$$\text{s.t. } g_i(x) \leq 0, \quad i = 1, \dots, m$$

$$h_i(x) = 0, \quad i = 1, \dots, p$$

$$x \in \mathcal{X}$$

Let (x_*, λ_*, μ_*) be a saddle point.

Then for all $\begin{cases} x \in \mathcal{X} \\ \lambda \in \mathbb{R}_+^m \\ \nu \in \mathbb{R}^p \end{cases}$ it holds that $L(x_*, \lambda, \mu) \leq L(x, \lambda_*, \mu_*)$.

o True

o (江如俊教授 Note 5 定义 1.3)

考虑一般优化问题:

$$\begin{aligned} \min & f(x) \\ \text{(P)} \quad \text{s.t.} & g_i(x) \leq 0, i = 1, \dots, m \\ & h_i(x) = 0, i = 1, \dots, p \\ & x \in \mathcal{X} \end{aligned}$$

定义其 Lagrange 函数为:

$$\begin{cases} L(x, \lambda, \nu) = f(x) + \sum_{i=1}^m \lambda_i g_i(x) + \sum_{i=1}^p \nu_i h_i(x) = f(x) + \lambda^T g(x) + \nu^T h(x) \\ \text{dom}(L) = \mathcal{X} \times \mathbb{R}_+^m \times \mathbb{R}^p \end{cases}$$

鞍点的定义:

若 $(x_*, \lambda_*, \nu_*) \in \text{dom}(L)$ 满足:

对于任意 $x \in \mathcal{X}$ 和 $(\lambda, \nu) \in \mathbb{R}_+^m \times \mathbb{R}^p$ 都有 $L(x_*, \lambda, \nu) \leq L(x_*, \lambda_*, \nu_*) \leq L(x, \lambda_*, \nu_*)$ 成立,

$$\text{即} \begin{cases} x_* = \arg \max_{(\lambda, \nu) \in \mathbb{R}_+^m \times \mathbb{R}^p} L(x, \lambda_*, \nu_*) \\ (\lambda_*, \nu_*) = \arg \min_{x \in \mathcal{X}} L(x, \lambda, \nu) \end{cases} \quad (x_* \text{ 最小化 } L(x, \lambda_*, \nu_*) \text{ 而 } (\lambda_*, \nu_*) \text{ 最大化 } L(x_*, \lambda, \nu))$$

则我们称 $(x_*, \lambda_*, \nu_*) \in \text{dom}(L)$ 是 $L(x, \lambda, \nu)$ 的一个鞍点.

3. Consider the unconstrained optimization problem $\min_{x \in \mathbb{R}^n} f(x)$

If $\begin{cases} \nabla f(\bar{x}) = 0_n \\ \nabla^2 f(\bar{x}) \succeq 0 \end{cases}$, then \bar{x} is a local minimum.

o False

o 这个命题中的条件只是 (二阶连续可微) 无约束优化问题的二阶必要条件, 并不充分.

考虑反例 $f(x) = x^5$, $x_0 = 0$ 满足 $\begin{cases} f'(x_0) = 0 \\ f''(x_0) = 0 \end{cases}$ 但它不是问题的局部最小点 (实际上是拐点).

o (江如俊教授 Note 4 命题 2.5)

定理 4.1.5: 无约束局部最小点的二阶必要条件 (Second Order Necessary Condition)

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 在 $x_0 \in \text{dom}(f)$ 处二阶连续可微 (twice continuously differentiable)

若 x_0 是 f 的一个局部最小点,

即 $f(x_0)$ 是 x_0 某邻域内目标函数的最小值,

即存在 $\varepsilon > 0$ 使得 $f(x_0) = \inf_{x \in B(x_0, \varepsilon)} f(x)$ (其中 Euclid 球 $B(x_0, \varepsilon)$ 代表 x_0 的邻域)

则有 $\begin{cases} \nabla f(x_0) = 0_n \\ \nabla^2 f(x_0) \succeq 0 \end{cases}$ 成立 (即 x_0 为非严格凸的驻点)

4. The positive semi-definite cone \mathbb{S}_+^n is a self-dual cone.

o True

o (江如俊教授 Note 5-2024 2.1 节末尾)

5. If $f(x)$ is convex, so is $g(x) = (c^T x + d)f(\frac{Ax+b}{c^T x+d})$.

Note that $\text{dom}(g) = \{x : \begin{cases} c^T x + d > 0 \\ \frac{Ax+b}{c^T x+d} \in \text{dom}(f) \end{cases}\}$

o True

- 参考这篇笔记 [FDU 最优化方法 3. 凸函数](#) 的 4.(3)(III) 节,
那里说明了凸函数 $f(x)$ 的线性分式透视 $g(x) = (c^T x + d)f(\frac{Ax+b}{c^T x+d})$ 也是凸函数.

6. A set is convex iff. its convex hull is convex.

- False**
- This is bullshit.
Whatever the set S is, its convex hull $\text{conv}(S)$ is naturally convex,
because it represents the smallest convex set that contains S .

7. The largest eigenvalue of symmetric matrix A is the optimal solution for the SDP problem:

$$\begin{aligned} \min_{\lambda \in \mathbb{R}} \quad & \lambda \\ \text{s.t.} \quad & \lambda I \succeq A \end{aligned}$$

- True**
- (要素察觉: Prof. smy & Advanced Linear Algebra)

8. The Lagrange duals of the standard QCQP problem and its SDP relaxation are not equivalent.

- False**
- (江如俊教授 Note 5 2.3.1节)

9. Let $f(x) = |\log(a^T x)|$, then $g(x) = \exp\{f(x)\}$ is convex on $\{x | a^T x > 0\}$.

- True**
- 注意到 $f(x) = |\log(a^T x)| = \begin{cases} -\log(a^T x), & \text{if } 0 < a^T x \leq 1 \\ \log(a^T x), & \text{if } a^T x > 1 \end{cases}$
因此 $g(x) = \exp\{f(x)\} = \begin{cases} \frac{1}{a^T x}, & \text{if } 0 < a^T x \leq 1 \\ \log(a^T x), & \text{if } a^T x > 1 \end{cases}$
引入映射 $\begin{cases} h(u) = \begin{cases} \frac{1}{u}, & \text{if } 0 < u \leq 1 \\ \log(u), & \text{if } u > 1 \end{cases} \\ p(x) = a^T x \end{cases}$ 则 $g(x) = h(p(x))$

根据 [FDU 最优化方法 3. 凸函数](#) 3.(2) 中有关仿射函数参与函数复合的相关结论,
函数 $g(x)$ 的凸/凹性与 $h(u)$ 的凸/凹性一致.

而我们将 $h(u)$ 的图像画出来, 很容易知道 $h(u)$ 是凸函数,
因此 $g(x)$ 也是凸函数.

10. $f(x)$ is a convex function iff. $\text{epi}(f)$ is a convex set.

- True**
- 上境图的基本性质参见 [FDU 最优化方法 3. 凸函数](#) 1.(4) 节

Problem 2 (15 Points)

Derive the dual of the following **relative entropy** problem:

$$\begin{aligned} \min_{x \in \mathbb{R}_+^n} \quad & \sum_{i=1}^n x_i \log\left(\frac{x_i}{y_i}\right) \\ \text{(P)} \quad \text{s.t.} \quad & Ax = b \\ & \mathbf{1}_n^T x = 1 \end{aligned}$$

where $y \in \mathbb{R}_{++}^n$ and $b \in \mathbb{R}^m$ are given.

Denote a_i as the i -th column of $A \in \mathbb{R}^{m \times n}$.

Solution:

分别为约束 $\begin{cases} Ax = b \\ 1_n^T x = 1 \end{cases}$ 引入 Lagrange 乘子 $\begin{cases} \nu \in \mathbb{R}^m \\ \mu \in \mathbb{R} \end{cases}$

定义 **Lagrange 函数**为:

$$\begin{aligned} L(x, \nu, \mu) &= \sum_{i=1}^n x_i \log\left(\frac{x_i}{y_i}\right) + \nu^T (b - Ax) + \mu(1 - 1_n^T x) \\ &= x^T \log(x) - \log(y)^T x - \nu^T Ax - \mu 1_n^T x + b^T \nu + \mu \end{aligned}$$

注意到对于任意 $i = 1, \dots, n$, 负熵函数 $x_i \log(x_i)$ 是关于 $x \in \mathbb{R}_+^n$ 的凸函数,

(为严谨起见, 我们额外定义 $0 \log(0) = 0$)

因此 $L(x, \nu, \mu)$ 关于 $x \in \mathbb{R}_+^n$ 是凸函数, 其驻点 (即为 \bar{x}) 一定能够最小化 $L(x, \nu, \mu)$.

求解驻点条件 $\nabla_x L(x, \nu, \mu) = 1_n + \log(x) - \log(y) - A^T \nu - \mu 1_n = 0_n$

我们有 $\begin{cases} \log(\bar{x}) - \log(y) = A^T \nu + \mu 1_n - 1_n \\ \bar{x} = y \circ \exp\{A^T \nu + \mu 1_n - 1_n\} \end{cases}$ 成立.

其中 \circ 代表向量的逐元素乘积 (Hadamard 乘积)

定义 **Lagrange 对偶函数**为:

$$\begin{aligned} d_1(\nu, \mu) &= \inf_{x \in \mathbb{R}_+^n} L(x, \nu, \mu) \\ &= L(\bar{x}, \nu, \mu) \\ &= \bar{x}^T (\log(\bar{x}) - \log(y)) - \nu^T A \bar{x} - \mu 1_n^T \bar{x} + b^T \nu + \mu \\ &= \bar{x}^T (A^T \nu + \mu 1_n - 1_n) - \nu^T A \bar{x} - \mu 1_n^T \bar{x} + b^T \nu + \mu \\ &= -1_n^T \bar{x} + b^T \nu + \mu \\ &= -1_n^T (y \circ \exp\{A^T \nu + \mu 1_n - 1_n\}) + b^T \nu + \mu \\ &= -\sum_{i=1}^m y_i e^{a_i^T \nu + \mu - 1} + b^T \nu + \mu \\ &= -e^{\mu-1} \cdot \sum_{i=1}^m y_i e^{a_i^T \nu} + b^T \nu + \mu \end{aligned}$$

因此**对偶问题**为:

$$\begin{aligned} \max \quad & -e^{\mu-1} \cdot \sum_{i=1}^m y_i e^{a_i^T \nu} + b^T \nu + \mu \\ \text{(D)} \quad \text{s.t.} \quad & \nu \in \mathbb{R}^m \\ & \mu \in \mathbb{R} \end{aligned}$$

注意到优化变量 ν, μ 是相互独立的, 且 $d_1(\nu, \mu)$ 关于 μ 为凹函数,

因此我们可以单独在 $\mu \in \mathbb{R}$ 上最大化 (D) 的目标函数 $d_1(\nu, \mu)$ 来简化 (D):

由于 $d_1(\nu, \mu)$ 关于 μ 为凹函数, 故其驻点 (记为 $\bar{\mu}$) 一定是最大值点.

求解驻点条件:

$$\begin{aligned} \frac{\partial}{\partial \mu} d_1(\nu, \mu) &= \frac{\partial}{\partial \mu} \{-e^{\mu-1} \cdot \sum_{i=1}^m y_i e^{a_i^T \nu} + b^T \nu + \mu\} \\ &= -e^{\mu-1} \cdot \sum_{i=1}^m y_i e^{a_i^T \nu} + 1 \end{aligned}$$

$$\text{于是有} \begin{cases} = 0 \\ e^{\bar{\mu}-1} \cdot \sum_{i=1}^m y_i e^{a_i^T \nu} = 1 \\ \bar{\mu} = -\log\left(\sum_{i=1}^m y_i e^{a_i^T \nu}\right) + 1 \end{cases}$$

我们定义新的对偶函数:

$$\begin{aligned}
 d_2(\nu) &= \sup_{\mu \in \mathbb{R}} d_1(\lambda, \mu) \\
 &= d_1(\lambda, \bar{\mu}) \\
 &= -e^{\bar{\mu}-1} \cdot \sum_{i=1}^m y_i e^{a_i^T \nu} + b^T \nu + \bar{\mu} \\
 &= -1 + b^T \nu - \log\left(\sum_{i=1}^m y_i e^{a_i^T \nu - 1}\right) + 1 \\
 &= b^T \nu - \log\left(\sum_{i=1}^m y_i e^{a_i^T \nu - 1}\right)
 \end{aligned}$$

最终得到对偶问题的化简形式:

$$\begin{aligned}
 (\text{simpleD}) \quad & \max \quad b^T \nu - \log\left(\sum_{i=1}^m y_i e^{a_i^T \nu - 1}\right) \\
 \text{s.t.} \quad & \nu \in \mathbb{R}^m
 \end{aligned}$$

Problem 3 (15 Points)

考虑优化问题:

$$\begin{aligned}
 (\text{P}) \quad & \min \quad \frac{\|Ax - b\|_1^2}{1 - \|x\|_\infty} \\
 \text{s.t.} \quad & \|x\|_\infty \leq \frac{1}{2}
 \end{aligned}$$

其中 $A \in \mathbb{R}^{m \times n}$ 和 $b \in \mathbb{R}^m$ 已经给定.

请将问题 (P) 转化为 SOCP (Second-Order Cone Program) 形式.
(即具有线性目标函数、线性约束和二阶锥约束)

Solution:

首先我们向问题 (P) 引入变量 $t \in \mathbb{R}$ 和约束 $\frac{\|Ax - b\|_1^2}{1 - \|x\|_\infty} \leq t$, 得到:

$$\begin{aligned}
 (\text{P1}) \quad & \min_{x,t} \quad t \\
 \text{s.t.} \quad & \frac{\|Ax - b\|_1^2}{1 - \|x\|_\infty} \leq t \\
 & \|x\|_\infty \leq \frac{1}{2}
 \end{aligned}$$

考虑为 l_1 范数和 l_∞ 范数引入松弛变量 $\begin{cases} u \in \mathbb{R}^m \\ s \in \mathbb{R} \end{cases}$ 和约束 $\begin{cases} -u \preceq Ax - b \preceq u \\ -s1_n \preceq x \preceq s1_n \end{cases}$,

则我们可以将 $\begin{cases} \|Ax - b\|_1 \\ \|x\|_\infty \end{cases}$ 分别替换为它们的上界 $\begin{cases} 1_m^T u \\ s \end{cases}$

于是我们得到:

$$\begin{aligned}
 (\text{P2}) \quad & \min_{x,t,u,s} \quad t \\
 \text{s.t.} \quad & (1_m^T u)^2 \leq t(1 - s) \\
 & s \leq \frac{1}{2} \\
 & -u \preceq Ax - b \preceq u \\
 & -s1_n \preceq x \preceq s1_n
 \end{aligned}$$

注意到 $(1_m^T u)^2 \leq t(1-s)$ 实际上是一个**旋转的二阶锥约束** (rotated second-order constraint)

它可以等价变形为:

$$(1_m^T u)^2 + \frac{1}{4}[t - (1-s)]^2 \leq \frac{1}{4}[t + (1-s)]^2$$

根据 $\begin{cases} t \geq 0 \\ 1-s \geq 0 \end{cases}$ 可知 $t + (1-s) \geq 0$, 因此上述约束可等价变形为:

$$\left\| \begin{bmatrix} 1_m^T u \\ \frac{1}{2}(t+s-1) \end{bmatrix} \right\|_2 \leq \frac{1}{2}(t-s+1)$$

即标准形式的二阶锥约束.

因此 (P2) 即为问题 (P) 的 SOCP 形式.

Problem 4 (15 Points)

设 $f_i(x)$, $i = 1, \dots, m$ 为有限个 $\mathbb{R}^n \mapsto \mathbb{R}$ 的凸函数.

(1) 证明 $g(x) = \inf_{z_1 + \dots + z_m = x} \left\{ \sum_{i=1}^m f_i(z_i) \right\}$ 是一个 $\mathbb{R} \mapsto \mathbb{R}$ 的凸函数. (5 Points)

Solution:

任意给定 $x_1, x_2 \in \mathbb{R}$

对于任意 $\alpha \in (0, 1)$, 我们都有:

$$\begin{aligned} g(\alpha x_1 + (1-\alpha)x_2) &= \inf_{z_1 + \dots + z_m = \alpha x_1 + (1-\alpha)x_2} \left\{ \sum_{i=1}^m f_i(z_i) \right\} \\ &= \inf_{\left\{ \sum_{i=1}^m f_i(\alpha z_i^{(1)} + (1-\alpha)z_i^{(2)}) : \begin{cases} z_1^{(1)} + \dots + z_m^{(1)} = x_1 \\ z_1^{(2)} + \dots + z_m^{(2)} = x_2 \end{cases} \right\}} \\ &\leq \inf_{\left\{ \sum_{i=1}^m [\alpha f_i(z_i^{(1)}) + (1-\alpha)f_i(z_i^{(2)})] : \begin{cases} z_1^{(1)} + \dots + z_m^{(1)} = x_1 \\ z_1^{(2)} + \dots + z_m^{(2)} = x_2 \end{cases} \right\}} \quad (\text{利用 } f_i \text{ 的凸性}) \\ &= \inf_{\left\{ \alpha \sum_{i=1}^m f_i(z_i^{(1)}) + (1-\alpha) \sum_{i=1}^m f_i(z_i^{(2)}) : \begin{cases} z_1^{(1)} + \dots + z_m^{(1)} = x_1 \\ z_1^{(2)} + \dots + z_m^{(2)} = x_2 \end{cases} \right\}} \\ &= \alpha \inf_{z_1^{(1)} + \dots + z_m^{(1)} = x_1} \left\{ \sum_{i=1}^m f_i(z_i^{(1)}) \right\} + (1-\alpha) \inf_{z_1^{(2)} + \dots + z_m^{(2)} = x_2} \left\{ \sum_{i=1}^m f_i(z_i^{(2)}) \right\} \\ &= \alpha g(x_1) + (1-\alpha)g(x_2) \end{aligned}$$

因此 $g(x)$ 是凸函数.

(2) 证明 $g(x) = \inf_{z_1 + \dots + z_m = x} \left\{ \sum_{i=1}^m f_i(z_i) \right\}$ 的共轭函数 $g^*(y) = \sum_{i=1}^m f_i^*(y)$. (10 Points)

Solution:

任意给定 $y \in \mathbb{R}$, 我们都有:

$$\begin{aligned} g^*(y) &= \sup_{x \in \mathbb{R}} \{yx - g(x)\} \\ &= \sup_{x \in \mathbb{R}} \{yx - \inf_{z_1 + \dots + z_m = x} \{\sum_{i=1}^m f_i(z_i)\}\} \\ &= \sup_{x \in \mathbb{R}} \sup_{z_1 + \dots + z_m = x} \{\sum_{i=1}^m [yz_i - f_i(z_i)]\} \\ &= \sup_{\substack{z_1, \dots, z_m, x \in \mathbb{R} \\ z_1 + \dots + z_m = x}} \{\sum_{i=1}^m [yz_i - f_i(z_i)]\} \\ &= \sup_{z_1, \dots, z_m \in \mathbb{R}} \{\sum_{i=1}^m [yz_i - f_i(z_i)]\} \\ &= \sum_{i=1}^m \sup_{z_i \in \mathbb{R}} \{yz_i - f_i(z_i)\} \\ &= \sum_{i=1}^m f_i^*(y) \end{aligned}$$

因此对于任意 $y \in \mathbb{R}$ 都有 $g^*(y) = \sum_{i=1}^m f_i^*(y)$ 成立.

Problem 5 (10 Points)

考虑二次规划问题:

$$\begin{aligned} \text{(P)} \quad & \min_{x \in \mathbb{R}^3} \quad \frac{1}{2} x^T P x + q^T x + r \\ \text{s.t.} \quad & -1 \leq x_i \leq 1, \quad i = 1, 2, 3 \\ \text{其中 } P = & \begin{bmatrix} 13 & 12 & -2 \\ 12 & 17 & 6 \\ -2 & 6 & 12 \end{bmatrix}, q = \begin{bmatrix} 22 \\ -14.5 \\ 13 \end{bmatrix}, r = 1 \end{aligned}$$

请证明 $x_* = (1, \frac{1}{2}, -1)$ 是问题 (P) 的全局最优解.

Solution:

首先我们证明 (P) 是一个凸问题 (这是为了使用 KKT 条件作为全局最优解的充分条件):

由于 (P) 只具有线性约束, 故我们只需证明目标函数为凸函数即可, 即要证矩阵 P 是半正定的.

• **一阶顺序主子式:** $\det([13]) = 13 > 0$

• **二阶顺序主子式:** $\det \begin{bmatrix} 13 & 12 \\ 12 & 17 \end{bmatrix} = 13 \times 17 - 12 \times 12 > 0$

• **三阶顺序主子式:**

$$\begin{aligned} \det \begin{bmatrix} 13 & 12 & -2 \\ 12 & 17 & 6 \\ -2 & 6 & 12 \end{bmatrix} &= 13 \det \begin{bmatrix} 17 & 6 \\ 6 & 12 \end{bmatrix} - 12 \det \begin{bmatrix} 12 & 6 \\ -2 & 12 \end{bmatrix} + (-2) \det \begin{bmatrix} 12 & 17 \\ -2 & 6 \end{bmatrix} \\ &= 13(17 \times 12 - 36) - 12(12 \times 12 + 12) - 2(72 + 34) \\ &= 13 \times 168 - 12 \times 156 - 212 \\ &= 13 \times (168 - 156) - (212 - 156) \\ &= 13 \times 12 - 56 \\ &> 0 \end{aligned}$$

因此 P 是半正定阵 (更具体来说, 它是正定阵),

说明问题 (P) 是一个凸优化问题.

根据 **Lemma** (参见后文) 我们知道 KKT 条件是全局最优解的充分条件, 我们只需要验证 $x_* = (1, \frac{1}{2}, -1)$ 满足 KKT 条件, 即可证明 x_* 是 (P) 的全局最优解.

我们忽略 (P) 的目标函数中的常数项 $r = 1$, 得到:

$$(\text{newP}) \min_{x \in \mathbb{R}^3} \frac{1}{2} x^T P x + q^T x$$

$$\text{s.t.} \quad -1 \leq x_i \leq 1, \quad i = 1, 2, 3$$

我们引入 Lagrange 乘子 $\lambda, \nu \in \mathbb{R}^3$, 定义 (newP) 的 Lagrange 函数为:

$$L(x, \lambda, \nu) = \frac{1}{2} x^T P x + q^T x + \sum_{i=1}^3 \lambda_i (x_i - 1) + \sum_{i=1}^3 \nu_i (-1 - x_i)$$

我们列出 KKT 条件:

- **可行性条件:** $-1 \leq x_i \leq 1, \quad i = 1, 2, 3$

- **一阶必要条件:**

$$\nabla_x L(x, \lambda, \nu) = P x + q + \lambda - \nu$$

$$= \begin{bmatrix} 13 & 12 & -2 \\ 12 & 17 & 6 \\ -2 & 6 & 12 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} + \begin{bmatrix} \lambda_1 \\ \lambda_2 \\ \lambda_3 \end{bmatrix} - \begin{bmatrix} \nu_1 \\ \nu_2 \\ \nu_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

$$\text{即} \begin{cases} 13x_1 + 12x_2 - 2x_3 + \lambda_1 - \nu_1 = 0 \\ 12x_1 + 17x_2 + 6x_3 + \lambda_2 - \nu_2 = 0 \\ -2x_1 + 6x_2 + 12x_3 + \lambda_3 - \nu_3 = 0 \end{cases}$$

- **对偶可行性条件:** $\lambda_1, \lambda_2, \lambda_3, \nu_1, \nu_2, \nu_3 \geq 0$

- **(弱) 互补松弛条件:** $\begin{cases} \lambda_i (x_i - 1) = 0, & i = 1, 2, 3 \\ \nu_i (-1 - x_i) = 0, & i = 1, 2, 3 \end{cases}$

我们令 $x = x_* = (1, \frac{1}{2}, -1)$ (注意这是一个可行点),

$$\text{代入 KKT 系统得到} \begin{cases} -1 + \lambda_1 - \nu_1 = 0 \\ 0 + \lambda_2 - \nu_2 = 0 \\ 2 + \lambda_3 - \nu_3 = 0 \\ \nu_1 = 0 \\ \lambda_2 = \nu_2 = 0 \\ \lambda_3 = 0 \end{cases} \quad \text{进而解得} \begin{cases} \lambda = (1, 0, 0) \\ \nu = (0, 0, 2) \end{cases} \quad (\text{注意它们是对偶可行的})$$

因此对于 $x_* = (1, \frac{1}{2}, -1)$,

存在 Lagrange 乘子 $\begin{cases} \lambda_* = (1, 0, 0) \\ \nu_* = (0, 0, 2) \end{cases}$ 使得 (x_*, λ_*, ν_*) 满足 KKT 条件,

故 $x_* = (1, \frac{1}{2}, -1)$ 是一个 KKT 点,

结合问题 (P) 的凸性可知 $x_* = (1, \frac{1}{2}, -1)$ 是全局最优解.

Lemma:

定理 4.2.6: (凸优化问题中全局最优解的充分条件, 江如俊教授 Note 4 Theorem 3.7)

考虑凸优化问题:

$$(\text{P}) \begin{cases} \min & f(x) \\ \text{s.t.} & g_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_i(x) = 0, \quad i = 1, \dots, p \\ & x \in \mathcal{X} \end{cases}$$

其中 $\mathcal{X} \subseteq \mathbb{R}^n$ 为开凸集, f, g_1, \dots, g_m 为 \mathcal{X} 上的凸函数, h_1, \dots, h_p 是仿射函数.

定义 Lagrange 函数为:

$$\begin{cases} L(x, \lambda, \nu) = f(x) + \sum_{i=1}^m \lambda_i g_i(x) + \sum_{i=1}^p \nu_i h_i(x) = f(x) + \lambda^T g(x) + \nu^T h(x) \\ \text{dom}(L) = \mathcal{X} \times \mathbb{R}^m \times \mathbb{R}^p \end{cases}$$

若 $(x_*, \lambda_*, \nu_*) \in \mathcal{X} \times \mathbb{R}^m \times \mathbb{R}^p$ 是一个 KKT 点, 即满足:

- **可行性条件:** $\begin{cases} g(x_*) \preceq 0_m \\ h(x_*) = 0_p \end{cases}$

- **一阶必要条件:** $\nabla_x L(x_*, \lambda_*, \nu_*) = \nabla f(x_*) + \sum_{i=1}^m \lambda_i^* \nabla g_i(x_*) + \sum_{i=1}^p \nu_i^* \nabla h_i(x_*) = 0_n$
- **对偶可行性条件:** $\lambda_* \succeq 0_m$
- **(弱) 互补松弛条件:** $\lambda_i^* g_i(x_*) = 0 \quad (\forall i = 1, \dots, m)$

则 x_* 是凸优化问题 (P) 的全局最优解.

Problem 6 (25 Points)

Consider the following Minimax problem denoted (1):

$$\min_x \max_{i=1, \dots, m} f_i(x) \quad (1)$$

where $f_1, \dots, f_m : \mathbb{R}^n \mapsto \mathbb{R}$ are continuously differentiable convex functions.

(1) is equivalent to the one denoted (2):

$$\begin{aligned} \min_x \max_y \sum_{i=1}^m y_i f_i(x) \\ \text{s.t. } y \succeq 0_m \\ 1_m^T y = 1 \end{aligned} \quad (2)$$

(a) List the optimality conditions for problem (2). (8 Points)

Hint:

You should fix x first, and derive the KKT conditions for the inner maximization problem.

Apply Lagrange multipliers $\begin{cases} \lambda \in \mathbb{R}^m \\ \nu \in \mathbb{R} \end{cases}$ for the constraints $\begin{cases} y \succeq 0_m \\ 1_m^T y = 1 \end{cases}$, respectively.

Then you should fix y , and derive the first-order optimality conditions for the outer minimization problem.

Solution:

首先固定 $x \in \mathbb{R}^n$, 考虑关于 $y \in \mathbb{R}^m$ 的最大化问题:

$$\begin{aligned} \max_y \sum_{i=1}^m y_i f_i(x) \\ \text{(P1) s.t. } y \succeq 0_m \\ 1_m^T y = 1 \end{aligned}$$

显然 (P1) 是一个凸优化问题, 因为它只具有线性约束, 且目标函数关于 $y \in \mathbb{R}^m$ 仿射 (自然是凸的).

又注意到 (P1) 的任意可行点都是正则的,

结合问题的凸性我们知道 KKT 条件是 (P1) 全局最优解的**充要条件**.

定义 (P1) 的 Lagrange 函数为 $L(y, \lambda, \nu) = \sum_{i=1}^m y_i f_i(x) + \lambda^T (y - 0_m) + \nu(1 - 1_m^T y)$

(注意 (P1) 是最大化问题, 定义 Lagrange 函数时需要格外谨慎)

则 **KKT 条件**如下:

- **可行性条件:** $\begin{cases} y \succeq 0_m \\ 1_m^T y = 1 \end{cases}$

$$\bullet \text{ Lagrange 函数驻点条件: } \nabla_y L(y, \lambda, \nu) = \begin{bmatrix} f_1(x) + \lambda_1 - \nu \\ \vdots \\ f_m(x) + \lambda_m - \nu \end{bmatrix} = 0_m$$

- **对偶可行性条件:** $\lambda \succeq 0_m$

- **(弱) 互补松弛性:** $\lambda_i y_i = 0 \quad (\forall i = 1, \dots, m)$

现在固定 $y \in \mathbb{R}_+^m$, 考虑关于 $x \in \mathbb{R}^n$ 的最小化问题:

$$(P2) \min_x \sum_{i=1}^m y_i f_i(x)$$

这是一个无约束凸优化问题, 根据**一阶最优化条件**可知:

$x \in \mathbb{R}^n$ 为 (P2) 的全局最优值, 当且仅当 $\sum_{i=1}^m y_i \nabla f_i(x) = 0_n$ 成立.

综上所述, 问题 (2) 的最优性条件为:

$$\begin{cases} y \succeq 0_m \\ 1_m^T y = 1 \\ \lambda \succeq 0_m \\ f_i(x) = \nu - \lambda_i & (\forall i = 1, \dots, m) \\ \lambda_i y_i = 0 & (\forall i = 1, \dots, m) \\ \sum_{i=1}^m y_i \nabla f_i(x) = 0_n \end{cases}$$

(b) Denote
$$\begin{cases} T(x) = \{i : f_i(x) = \max_{j=1, \dots, m} f_j(x)\} \\ I(y) = \{i : y_i > 0\} \\ A(y) = \{i : y_i = 0\} \end{cases}$$

First show that for all $(x_*, y_*, \lambda_*, \nu_*)$ satisfying optimality conditions given in (a), we must have $I(y_*) \subseteq T(x_*)$.

Moreover, show that if $(x_*, y_*, \lambda_*, \nu_*)$ is strictly complementary (i.e. $\forall i \in A(y_*), \lambda_i^* > 0$), then $I(y_*) = T(x_*)$. (7 Points)

Solution:

• **证明第一个命题:**

假设 $(x_*, y_*, \lambda_*, \nu_*)$ 满足 (a) 中的最优性条件.

对于任意 $i \in I(y_*)$, 我们有 $y_i^* > 0$ 成立.

根据 (弱) 互补松弛性可知 $\lambda_i^* = 0$, 进而有 $f_i(x_*) = \nu_* - \lambda_i^* = \nu_*$.

注意到: 对于任意 $j = 1, \dots, m$ 都有 $f_j(x_*) = \nu_* - \lambda_j^* \leq \nu_*$ 成立.

因此 $f_i(x_*) = \max_{j=1, \dots, m} f_j(x_*)$, 说明 $i \in T(x_*)$.

得证 $I(y_*) \subseteq T(x_*)$

• **证明第二个命题:**

假设 $(x_*, y_*, \lambda_*, \nu_*)$ 满足 (a) 中的最优性条件, 且满足严格互补松弛条件.

结合第一个命题可知, 要证明第二个命题, 只需证明 $T(x_*) \subseteq I(y_*)$ 即可.

对于任意 $i \in T(x_*)$, 我们有 $f_i(x_*) = \max_{j=1, \dots, m} f_j(x_*)$ 成立.

(反证法) 假设 $i \notin I(y_*)$ (即 $y_i^* = 0$),

则根据严格互补松弛条件可知 $\lambda_i^* > 0$.

结合
$$\begin{cases} f_i(x_*) = \max_{j=1, \dots, m} f_j(x_*) \\ f_j(x_*) = \nu_* - \lambda_j^* \quad (\forall j = 1, \dots, m) \end{cases}$$
 可知对于任意 $j = 1, \dots, m$ 都有 $\lambda_j^* \geq \lambda_i^* > 0$,

根据 (弱) 互补松弛条件可知, 对于任意 $j = 1, \dots, m$ 都有 $y_j^* = 0$ 成立,

进而有 $1_m^T y_* = 0$ 成立, 这与 (a) 中最优性条件里的 " $1_m^T y_* = 1$ " 矛盾.

因此反证法的假设不成立, 我们有 $i \in I(y_*)$ 成立,

得证 $T(x_*) \subseteq I(y_*)$

结合第一个命题, 进而得证 $I(y_*) = T(x_*)$

(c) Suppose the strict complementary assumptions holds (i.e. $\forall i \in A(y_*)$, $\lambda_i^* > 0$).

Denote $T(x) = \{j_1, \dots, j_{|T(x)|}\}$ where $|T(x)|$ represents the number of entries in $T(x)$.

$$\text{Define } M(x) = \begin{bmatrix} \nabla f_{j_1}(x) & \dots & \nabla f_{j_{|T(x)|}}(x) \\ 1 & \dots & 1 \end{bmatrix}$$

Prove for (x_*, y_*) satisfies the KKT conditions in (a),

the matrix $M(x_*)$ is of full column rank.

Hint:

You may assume that there exists a nonzero vector $c \in \mathbb{R}^{|T(x_*)|}$ such that $M(x_*)c = 0$ and use c and y^* to construct a counterexample.

Solution:

假设 (x_*, y_*) 满足 (a) 中的 KKT 条件, 且满足严格互补松弛条件.

(反证法) 假设存在 nonzero 向量 $c \in \mathbb{R}^{|T(x_*)|}$ 使得 $M(x_*)c = 0$ 成立.

不失一般性, 假设存在 $i \in T(x_*)$ 使得 $c_i > 0$ (如果不存在, 我们可以使用 $-c$ 代替 c)

根据 (b) 的结论, 可知有 $I(y_*) = T(x_*)$ 成立.

定义:

$$\begin{aligned} d &= \min \left\{ \frac{y_i^*}{c_i} : i \in I(y_*) \text{ such that } c_i > 0 \right\} \\ &= \min \left\{ \frac{y_i^*}{c_i} : i \in T(x_*) \text{ such that } c_i > 0 \right\} \end{aligned}$$

定义 $z \in \mathbb{R}^m$:

$$z_i = \begin{cases} y_i^* - c_i d & \text{if } i \in I(y_*) = T(x_*) \\ 0 & \text{otherwise} \end{cases}$$

根据 (b) 的结论, 可知有 $I(y_*) = T(x_*)$ 成立.

因此, 对于任意 $i \notin T(x_*)$, 都有 $i \notin I(y_*)$ 成立, 即有 $y_i^* = 0$ 成立.

而对于任意 $i \in T(x_*)$, 都有 $i \in I(y_*)$ 成立, 即有 $y_i^* > 0$ 成立.

于是我们有:

$$\begin{aligned} \sum_i^m y_i^* \nabla f_i(x_*) &= \sum_{i \notin T(x_*)} y_i^* \nabla f_i(x_*) + \sum_{i \in T(x_*)} y_i^* \nabla f_i(x_*) \\ &= \sum_{i \in T(x_*)} y_i^* \nabla f_i(x_*) \end{aligned}$$

(反证法) 假设存在不全为 0 的 $c \in \mathbb{R}^m$ 使得 $M(x_*)$ 的列线性组合为 0_{n+1} ,

$$\text{即使得 } \begin{cases} \sum_{i \in T(x_*)} c_i \nabla f_i(x_*) = 0_n \\ \sum_{i \in T(x_*)} c_i = 0 \end{cases} \text{ 成立.}$$

一定存在 $i_0 \in T(x_*)$ 使得 $c_{i_0} > 0$,

(d) If x^* is an optimal solution of (2), then there exists a unique y , such that (x^*, y, μ, v) solves the system given in (a).