

FDU 神经网络 3. 卷积神经网络

本文参考以下教材：

- 神经网络与深度学习 (邱锡鹏) 第 5 章
 - Deep Learning (I. Goodfellow, Y. Bengio, A. Courville) Chapter 7, 9
 - 深度学习 (I. Goodfellow, Y. Bengio, A. Courville, 赵申剑等译) 第 7, 9 章

欢迎批评指正!

3.1 卷积

3.1.1 卷积


卷积 (convolution) 是分析数学中一种重要的运算。

- ### • 一维卷积：


考虑长度为 K 的一维卷积核 $[w_1, \dots, w_K]$ 和一维信号序列 x_1, x_2, \dots 的卷积:(简单起见, 假设卷积结果 y 的首项元素的下标从 K 开始)

$$y := w \star x$$

$$y_t := \sum_{k=1}^K w_k x_{t-k+1} \ (\forall t \geq K)$$



(a) 濾波器 $[1/3, 1/3, 1/3]$



(b) 濾波器 $[1, -2, 1]$

图 5.1 一维卷积示例

下层为输入信号序列,上层为卷积结果,连接边上的数字为滤波器中的权重.

左图的卷积结果为近似值。

- ## • 二维卷积：

考虑二维图像 $X \in \mathbb{R}^{M \times N}$ 和二维卷积核 $W \in \mathbb{R}^{(2U+1) \times (2V+1)}$ (其中 $U \ll M, V \ll N$) 的卷积:

(简单起见，假设卷积结果 Y 的左上角元素的下标从 $(U + 1, V + 1)$ 开始，卷积核 W 中心点的下标为 $(0, 0)$)

$$Y := W \star X \in \mathbb{R}^{(M-2U) \times (N-2V)}$$

$$y_{ij} := \sum_{u=1}^U \sum_{v=1}^V w_{uv} x_{i-u, j-v}$$

where $U + 1 \leq i \leq M - U$ and $V + 1 \leq j \leq N - V$.

上述累积过程看起来就像这样：

1	1	1	1	1
-1	0	-3	0	1
2	1	1	-1	0
0	-1	1	2	1
1	2	1	1	1

*

1	0	0
0	0	0
0	0	-1

=

0	-2	-1
2	2	4
-1	0	0

图 5.2 二维卷积示例

根据卷积定义，左图的计算需要进行卷积核翻转。

如果我们先对图像 $X \in \mathbb{R}^{M \times N}$ 进行零填充 (上下两端各补 U 个零，左右各补 V 个零)

得到 $X_{\text{padded}} \in \mathbb{R}^{(M+2U) \times (N+2V)}$ 再进行卷积运算，

那么这样得到的卷积结果 $Y = W \star X_{\text{padded}}$ 的维度和原始图像 X 一样，都是 $M \times N$ 维的：
(简单起见，假设卷积核 W 中心点的下标为 $(0, 0)$)

$$Y := W \star X_{\text{padded}} \in \mathbb{R}^{M \times N}$$

$$y_{ij} := \sum_{u=-U}^U \sum_{v=-V}^V w_{uv} x_{i-u, j-v}$$

where $1 \leq i \leq M$ and $1 \leq j \leq N$

其中 $x_{i-u, j-v}$ 在超出原始图像范围时取零 (隐式零填充)

写在前面：

按最优化的记号，关于 z 的梯度应该用 ∇_z 符号表示 (标量对列向量求梯度得到的是同形的列向量)，

但为了方便我们使用 $\frac{\partial}{\partial z}$ 来代表梯度，尽管 $\frac{\partial}{\partial z}$ 符号在数学上代表导数 (标量对列向量求导数得到的是转置后同形的行向量)

机器学习的记号真是太混乱啦！而且与数学的记号不兼容。

无论如何，现在我们认为 $\frac{\partial}{\partial z}$ 代表梯度。

(邱锡鹏老师书上的记号也是这样默认的，不过着实让我困惑了一阵)

给定可微函数 $f : \mathbb{R}^{M \times N} \mapsto \mathbb{R}$ ，则我们有：(存疑)

$$\begin{aligned} \frac{\partial f(Y)}{\partial w_{u'v'}} &:= \sum_{i=1}^M \sum_{j=1}^N \frac{\partial y_{ij}}{\partial w_{u'v'}} \cdot \frac{\partial f(Y)}{\partial y_{ij}} \quad \left(\text{note that } y_{ij} := \sum_{u=-U}^U \sum_{v=-V}^V w_{uv} x_{i-u, j-v} \right) \\ &= \sum_{i=1}^M \sum_{j=1}^N x_{i-u', j-v'} \cdot \frac{\partial f(Y)}{\partial y_{ij}} \quad (-U \leq u' \leq U, -V \leq v' \leq V) \end{aligned}$$

$$\frac{\partial f(Y)}{\partial W} = \frac{\partial f(Y)}{\partial Y} \star \text{rotate}(X_{\text{padded}}, 180^\circ)$$

$$= \text{rotate}\left(\frac{\partial f(Y)}{\partial Y}, 180^\circ\right) \star X_{\text{padded}}$$

$$= \frac{\partial f(Y)}{\partial Y} * X_{\text{padded}}$$

其中 $*$ 是互相关运算， X_{padded} 是零填充的图像。

3.1.2 互相关

考虑二维图像 $X \in \mathbb{R}^{M \times N}$ 和二维卷积核 $W \in \mathbb{R}^{(2U+1) \times (2V+1)}$ (其中 $U \ll M, V \ll N$) 的互相关: (简单起见, 假设互相关结果 Y 的左上角元素的下标从 $(U + 1, V + 1)$ 开始, 卷积核 W 中心点的下标为 $(0, 0)$)

$$Y := W * X \in \mathbb{R}^{(M-2U) \times (N-2V)}$$
$$y_{ij} := \sum_{u=-U}^U \sum_{v=-V}^V w_{uv} x_{i+u, j+v}$$

where $U + 1 \leq i \leq M - U$ and $V + 1 \leq j \leq N - V$

互相关运算 $*$ 和卷积运算 \star 的区别在于, 互相关无需将卷积核旋转 180° , 而卷积需要. 换言之, 卷积运算相当于将卷积核旋转 180° 之后再做互相关运算:

$$W \star X = \text{rotate}(W, 180^\circ) * X$$

互相关和卷积的性质有所区别:

性质	互相关	卷积
交换律	(不满足)	$f \star g = g \star f$
结合律	(不满足)	$f \star (g \star h) = (f \star g) \star h$
分配律	$f * (g + h) = (f * g) + (f * h)$	$f \star (g + h) = (f \star g) + (f \star h)$

根据卷积的交换律可知旋转卷积核 W 还是旋转图像 X 是无关紧要的, 但按照惯例我们旋转 W .

根据卷积的结合律可知多次卷积可以合并为一次卷积.

3.2 卷积神经网络

卷积神经网络一般是由卷积层、汇聚层和全连接层交叉堆叠而成的前馈神经网络.

卷积神经网络有三个结构上的特性: 局部连接、权重共享和汇聚.

这些特性使得卷积神经网络具有一定度上的平移、缩放和旋转不变性, 更适用于图像相关的任务.

和前馈神经网络相比, 卷积神经网络的参数更少.

3.2.1 卷积层

相对于全连接层来说, 卷积层有两个重要性质:

- ① **局部连接:**

卷积层的每个神经元都只与前一层中某个局部窗口内的神经元相连, 有助于学习图像的局部特征.

- ② **权重共享:**

作为参数的卷积核 $W^{(l)}$ 对于卷积层的所有神经元都是相同的.

单个卷积核都可以视为在对输入的单个特征做提取.

以一维情况为例:





图 5.5 全连接层和卷积层对比

现考虑一般情况，假设卷积层的结构如下：

- 输入特征映射组: $\mathcal{X} \in \mathbb{R}^{M \times N \times D}$
其中第 $1 \leq d \leq D$ 个切片矩阵 $X^d \in \mathbb{R}^{M \times N}$ 为一个输入特征映射。
(图像相关的任务中，彩色图像通常有 RGB 三通道的特征映射，即 $D = 3$)
- 输出特征映射组: $\mathcal{Y} \in \mathbb{R}^{M' \times N' \times P}$
其中第 $1 \leq p \leq P$ 个切片矩阵 $Y^p \in \mathbb{R}^{M' \times N'}$ 为一个输出特征映射。
- 卷积核: $\mathcal{W} \in \mathbb{R}^{U \times V \times P \times D}$
其中切片矩阵 $W^{p,d} \in \mathbb{R}^{U \times V}$ 为二维卷积核 (其中 $1 \leq p \leq P$, $1 \leq d \leq D$)
- 偏置: $b \in \mathbb{R}^P$
(因此总参数量是 $U \times V \times P \times D + P$)




图 5.6 卷积层的三维结构表示

为计算输出特征映射 Y^p ，用卷积核 $W^{p,1}, \dots, W^{p,D}$ 分别对输入特征映射 X^1, \dots, X^D 进行卷积，
然后将卷积结果相加，并加上一个标量偏置 b^p 得到卷积层的净输入 Z^p ，
再经过非线性激活函数后得到输出特征映射 Y^p 。

$$\begin{aligned}
 Z^p &= W^p \star \mathcal{X} \\
 &= \sum_{d=1}^D W^{p,d} \star X^d + b^p \cdot \text{ones}(M', N') \\
 \hline
 Y^p &= f(Z^p)
 \end{aligned}$$

其中 $W^p = [W^{p,1}, \dots, W^{p,D}] \in \mathbb{R}^{U \times V \times D}$ 为三维卷积核, $f(\cdot)$ 为激活函数.
重复上述过程 P 次, 就得到 P 个输出特征映射 Y^1, \dots, Y^P .




图 5.7 卷积层中从输入特征映射组 \mathbf{X} 到输出特征映射 \mathbf{Y}^p 的计算示例

3.2.2 汇聚层

汇聚层 (pooling layer) 又称**池化层**, 用于特征筛选, 减少参数数量.

卷积层虽然可以显著减少网络中连接的数量, 但特征映射组中的神经元个数并没有显著减少.

如果后面直接接上全连接层, 则全连接层的输入维数依然很高, 很容易出现过拟合.

为了解决这个问题, 可以在卷积层之后加上一个汇聚层, 从而降低特征维数.

假设汇聚层的结构如下:

- 输入特征映射组: $\mathcal{X} \in \mathbb{R}^{M \times N \times D}$ (一般是卷积层的输出特征映射组)
其中第 $1 \leq d \leq D$ 个切片矩阵 $X^d \in \mathbb{R}^{M \times N}$ 为一个输入特征映射.
- 输出特征映射组: $\mathcal{Y} \in \mathbb{R}^{M' \times N' \times D}$ (汇聚层不改变特征维数)
其中第 $1 \leq d \leq D$ 个切片矩阵 $Y^d \in \mathbb{R}^{M' \times N'}$ 为一个输出特征映射.

对于第 d 个输入特征映射 $X^d \in \mathbb{R}^{M \times N}$,

我们将其划分为 $M' \times N'$ 个区域 $X_{m,n}^d$ (其中 $1 \leq m \leq M'$, $1 \leq n \leq N'$)

这些区域可以重叠, 也可以不重叠.

汇聚 (pooling) 就是对每个区域进行**下采样** (down sampling) 得到一个值, 作为整个区域的概括.

常用的汇聚函数有两种:

- ① 最大汇聚 (max pooling):

$$y_{m,n}^d := \text{maximum value of region } X_{m,n}^d$$

- ② 平均汇聚 (mean pooling):

$$y_{m,n}^d := \text{average value of region } X_{m,n}^d$$

典型的汇聚层是将每个特征映射划分为 2×2 大小的不重叠区域, 然后使用最大汇聚的方式进行下采样.
目前主流的卷积网络中, 汇聚层仅包含下采样操作, 不包含激活函数.




图 5.8 汇聚层中最大汇聚过程示例

汇聚层不但可以有效地减少神经元的数量，
还可以使得网络的神经元拥有更大的感受野，从而对于局部形态的改变具有更强的稳健性。

3.2.3 整体结构

一个典型的卷积网络是由卷积层、汇聚层、全连接层交叉堆叠而成。




图 5.9 常用的卷积网络整体结构

卷积块为连续 M (通常取 $2 \sim 5$) 个卷积层和 b (通常取 0 或 1) 个汇聚层。

卷积网络中可以堆叠 N ($1 \sim 100$ 或更大) 个连续的卷积块，然后接上 K (通常为 $0 \sim 2$) 个全连接层。目前卷积网络的整体结构趋向于使用更小的卷积核 (例如 1×1 和 3×3) 以及更深的结构 (例如 50 以上的层数)。

此外，由于卷积的操作性越来越灵活 (例如不同的步长)，汇聚层的作用也变得越来越小，因此在目前主流的卷积网络中，汇聚层的比例正在逐渐降低，趋向于全卷积网络。

3.2.4 反向传播

汇聚层：

设第 $l+1$ 层为汇聚层，来自第 l 层的输入特征映射组为 $\mathcal{X}^{(l)} \in \mathbb{R}^{M \times N \times D}$ ，通过汇聚得到第 $l+1$ 层的特征映射净输出 $\mathcal{Z}^{(l+1)} = \text{down}(\mathcal{X}^{(l)}) \in \mathbb{R}^{M' \times N' \times P}$ 。

因为汇聚层是下采样操作 $\text{down}(\cdot)$ ，所以反向传播时需要对偏导进行对应的上采样操作 $\text{up}(\cdot)$ ：

$$\begin{aligned}\frac{\partial \mathcal{L}}{\partial Z^{(l,p)}} &= \frac{\partial X^{(l,p)}}{\partial Z^{(l,p)}} \cdot \frac{\partial Z^{(l+1,p)}}{\partial X^{(l,p)}} \cdot \frac{\partial \mathcal{L}}{\partial Z^{(l+1,p)}} \quad (\text{note that } X^{(l,p)} = f_l(Z^{(l,p)})) \\ &= f'_l(Z^{(l,p)}) \odot \text{up} \left(\frac{\partial \mathcal{L}}{\partial Z^{(l+1,p)}} \right) \quad (1 \leq p \leq P)\end{aligned}$$

其中 $\text{up}(\cdot)$ 操作将 $\frac{\partial \mathcal{L}}{\partial Z^{(l,p)}}$ 上采样为与 $Z^{(l,p)}$ 同形的矩阵, 而 $f_l(\cdot)$ 是第 l 层(假设是卷积层)的激活函数.

卷积层:

设第 l 层为卷积层, 来自第 $l-1$ 层的输入特征映射组为 $\mathcal{X}^{(l-1)} \in \mathbb{R}^{M \times N \times D}$, 通过卷积计算得到第 l 层的特征映射净输出 $\mathcal{Z}^{(l)} \in \mathbb{R}^{M' \times N' \times P}$:

$$\begin{aligned}\mathcal{Z}^{(l)} &:= [Z^{(l,1)}, \dots, Z^{(l,P)}] \in \mathbb{R}^{M' \times N' \times P} \\ Z^{(l,p)} &= W^{(l,p)} \star \mathcal{X}^{(l-1)} + b^{(l,p)} \cdot \text{ones}(M', N') \\ &= \sum_{d=1}^D W^{(l,p,d)} \star X^{(l-1,p)} + b^{(l,p)} \cdot \text{ones}(M', N') \quad (1 \leq p \leq P) \\ \mathcal{X}^{(l)} &= f_l(\mathcal{Z}^{(l)}) \in \mathbb{R}^{M' \times N' \times P}\end{aligned}$$

其中 $W^{(l,p,d)}$ 为四维张量 $\mathcal{W}^{(l)} \in \mathbb{R}^{U \times V \times P \times D}$ 的第 (p, d) 个卷积核, 而 $b^{(l,p)}$ 为偏置向量 $b^{(l)} \in \mathbb{R}^P$ 的第 p 个分量, $f_l(\cdot)$ 是第 l 层的激活函数.

写在前面:

按最优化的记号, 关于 z 的梯度应该用 ∇_z 符号表示(标量对列向量求梯度得到的是同形的列向量),

但为了方便我们使用 $\frac{\partial}{\partial z}$ 来代表梯度, 尽管 $\frac{\partial}{\partial z}$ 符号在数学上代表导数(标量对列向量求导数得到的是转置后同形的行向量)

机器学习的记号真是太混乱啦! 而且与数学的记号不兼容.

无论如何, 现在我们认为 $\frac{\partial}{\partial z}$ 代表梯度.

(邱锡鹏老师书上的记号也是这样默认的, 不过着实让我困惑了一阵)

- 考虑损失函数 \mathcal{L} 关于第 l 层卷积核 $W^{(l,p,d)}$ 的偏导: (存疑)

$$\begin{aligned}\frac{\partial \mathcal{L}}{\partial W^{(l,p,d)}} &= \frac{\partial Z^{(l,p)}}{\partial W^{(l,p,d)}} \cdot \frac{\partial \mathcal{L}}{\partial Z^{(l,p)}} \\ &= \frac{\partial (W^{(l,p,d)} \star X^{(l-1,p)})}{\partial W^{(l,p,d)}} \cdot \frac{\partial \mathcal{L}}{\partial Z^{(l,p)}} \\ &= \left(\frac{\partial W^{(l,p,d)}}{\partial W^{(l,p,d)}} * X^{(l-1,p)} \right) \cdot \frac{\partial \mathcal{L}}{\partial Z^{(l,p)}} \quad (1 \leq d \leq D, 1 \leq p \leq P) \\ &= \frac{\partial \mathcal{L}}{\partial Z^{(l,p)}} * X^{(l-1,p)}\end{aligned}$$

其中 $*$ 是互相关运算.

- 考虑损失函数 \mathcal{L} 关于第 l 层偏置向量 $b^{(l)}$ 的偏导: (存疑)

$$\begin{aligned}\frac{\partial \mathcal{L}}{\partial b^{(l,p)}} &= \text{sum} \left(\frac{\partial Z^{(l,p)}}{\partial b^{(l,p)}} \cdot \frac{\partial \mathcal{L}}{\partial Z^{(l,p)}} \right) \\ &= \text{sum} \left(\text{ones}(M', N') \cdot \frac{\partial \mathcal{L}}{\partial Z^{(l,p)}} \right) \quad (1 \leq p \leq P) \\ &= \sum_{i=1}^M \sum_{j=1}^N \left[\frac{\partial \mathcal{L}}{\partial Z^{(l,p)}} \right]_{i,j}\end{aligned}$$

- 考虑到上一层(第 $l-1$ 层)的反向传播: (存疑)

$$\begin{aligned}
\frac{\partial \mathcal{L}}{\partial Z^{(l-1,d)}} &= \frac{\partial X^{(l-1,d)}}{\partial Z^{(l-1,d)}} \cdot \frac{\partial \mathcal{Z}^{(l)}}{\partial X^{(l-1,d)}} \cdot \frac{\partial \mathcal{L}}{\partial \mathcal{Z}^{(l)}} \\
&= f'_{l-1}(Z^{(l-1,d)}) \odot \sum_{p=1}^P \left(W^{(l,p,d)} * \frac{\partial \mathcal{L}}{\partial Z^{(l,p)}} \right)
\end{aligned}$$

其中我们假设第 $l - 1$ 层也是卷积层，激活函数为 $f_{l-1}(\cdot)$ ，而 $*$ 是自相关操作。

The End